Maestría en Inteligencia Artificial Aplicada

TTMZ0055 – Proyecto MIA

S8: BORRADOR INFORME FINAL

Integrantes:

Jorge Andrés Padilla

Alain Mateo Ruales

Marzo 2026

Tabla de Contenido

Tabla de Contenido 2
1. Introducción 3
1.1 Contextualización del problema organizacional 3
1.2 Justificación del proyecto y su relevancia 4
1.3 Objetivo general y objetivos específicos 4
Objetivo general 4
Objetivos específicos 5
2. Marco teórico y estado del arte 5
2.1 Principales aportes de la literatura 5
2.2 Tendencias, enfoques metodológicos y vacíos identificados 6
2.3 Relación con el problema abordado 6
3. Metodología 6
3.1 Diseño metodológico 6
3.2 Fuentes y preparación de datos 8
3.3 Técnicas y modelos de IA utilizados 10
3.4 Consideraciones éticas y de sesgo 11
4. Resultados preliminares 11
4.1 Descripción del prototipo desarrollado 11
4.2 Resultados obtenidos 14
Detector de odómetro 14
OCR 15
Evaluación end-to-end 16
Validación piloto 16
Análisis del umbral de validación 17
4.3 Análisis del desempeño del modelo 17
5. Validación e interpretabilidad 18
5.1 Técnicas de validación aplicadas 18
5.2 Análisis de interpretabilidad (XAI) 18
5.3 Pruebas de robustez realizadas 19
5.4 Riesgos identificados y estrategias de mitigación 20
6. Conclusiones preliminares, implicaciones y trabajo futuro 20
7. Referencias 21

1. Introducción

1.1 Contextualización del problema organizacional

SOLYTEC es una empresa ecuatoriana de servicios tecnológicos para compañías de agua potable. Dentro de su operación, uno de los procesos más sensibles corresponde a la toma de lecturas en campo para la facturación mensual. En este flujo, el operario captura una fotografía del medidor y registra manualmente la lectura observada. Aunque el sistema actual aplica una validación lógica para impedir que se ingrese un valor menor al del período anterior, no verifica si la imagen efectivamente respalda la lectura digitada.

Esta brecha afecta el aseguramiento de calidad de la información. Las imágenes se almacenan como evidencia documental, pero no son procesadas de forma sistemática para detectar discrepancias, capturas inválidas o lecturas con baja confiabilidad. Como resultado, la revisión se realiza principalmente por muestreo o de forma reactiva ante reclamos, lo que limita la cobertura frente a un volumen operativo que puede situarse entre 10,000 y 20,000 lecturas mensuales.

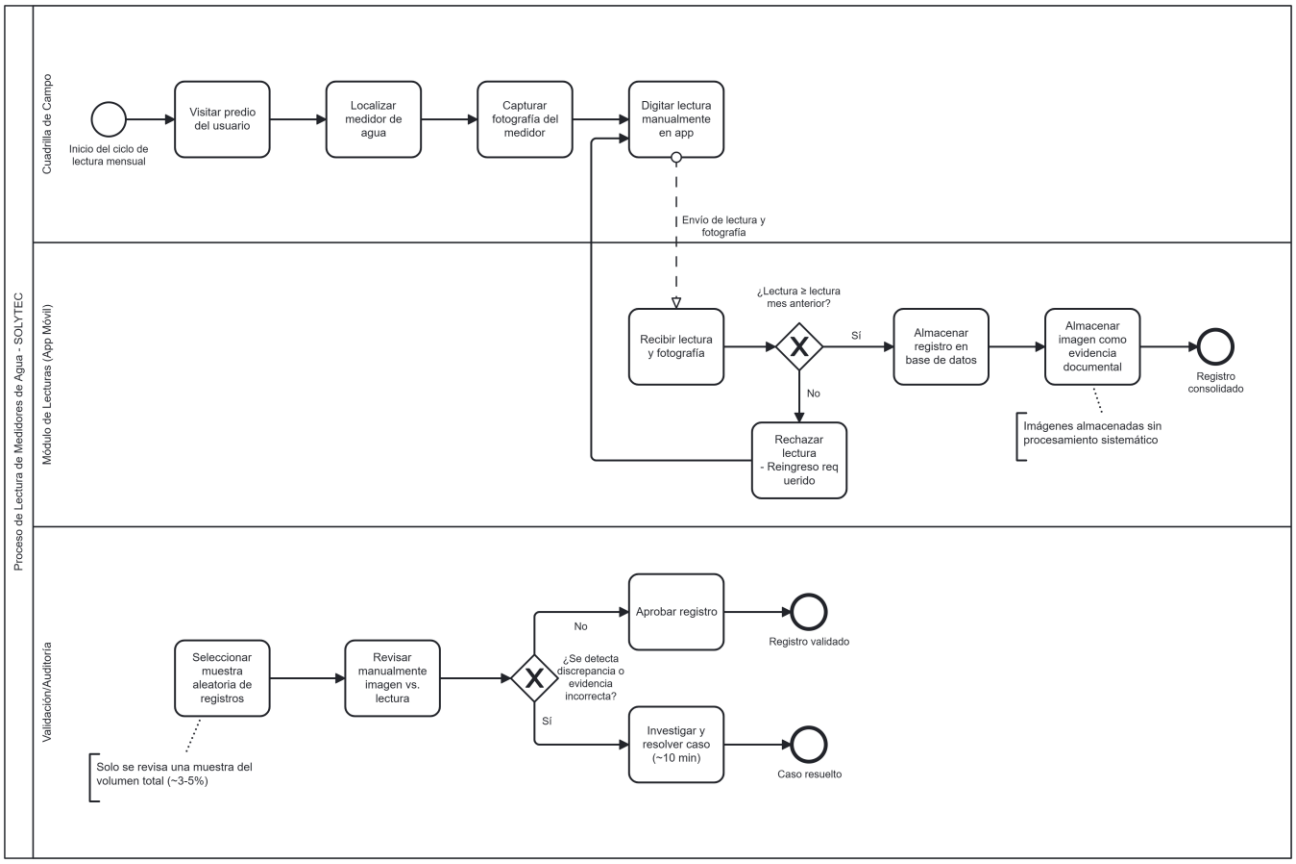

Figura 1. *Proceso actual de toma de lecturas y auditoría.*

En términos operativos, el problema se concentra en la interacción entre el módulo de captura de lecturas y el proceso de auditoría. La ausencia de un mecanismo automático para contrastar evidencia fotográfica y valor digitado permite que se almacenen registros con errores de digitación, imágenes borrosas, capturas mal encuadradas o evidencia insuficiente. Este escenario incrementa el riesgo de reprocesos, reclamos y pérdida de trazabilidad.

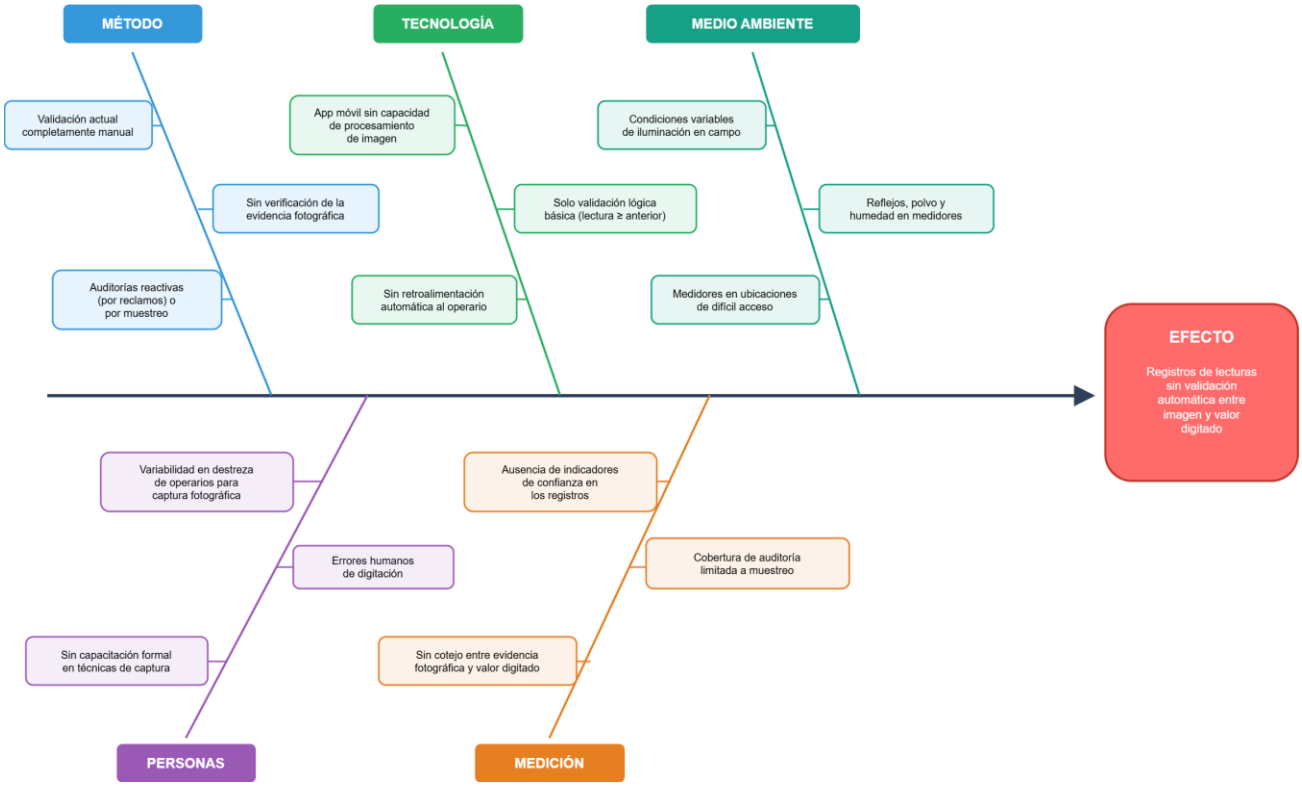

Figura 2. *Diagrama causa-efecto del problema.*

1.2 Justificación del proyecto y su relevancia

El proyecto se justifica por su valor organizacional y por su pertinencia técnica. Desde la perspectiva de negocio, una validación asistida de lecturas permite priorizar la revisión humana sobre los casos realmente dudosos, reducir errores de facturación y fortalecer la trazabilidad del proceso. Desde la perspectiva académica y tecnológica, el proyecto aborda un caso real de visión por computador aplicado al sector agua, donde todavía existen menos desarrollo tecnológico que en otros sectores de la industria.

La literatura reciente muestra que la lectura automática de medidores mediante imágenes constituye una vía práctica para modernizar infraestructura existente sin sustituir todos los dispositivos físicos (Zapata-Sierra et al., 2024). Sin embargo, la mayoría de los estudios se concentra en extraer la lectura del medidor, mientras que el problema identificado exige validar una lectura ya digitada dentro de un proceso operativo real. En ese sentido, el proyecto no busca automatizar el proceso de lecturas, sino adoptar un esquema de apoyo para agilizar la auditoría con un enfoque *human-in-the-loop*.

La relevancia del proyecto también radica en su aplicabilidad inmediata. Si el sistema logra localizar el odómetro, leer correctamente los dígitos enteros y emitir un indicador útil de confianza, la organización dispondrá de una base técnica para transformar una revisión reactiva en un control preventivo y escalable.

1.3 Objetivo general y objetivos específicos

Objetivo general

Desarrollar un sistema para la validación automática de lecturas de medidores de agua potable, basado en visión por computador y aprendizaje profundo, que analice la evidencia fotográfica,

extraiga el valor marcado y genere indicadores de confianza para apoyar el aseguramiento de calidad del proceso de toma de lecturas.

Objetivos específicos

- Construir un dataset anotado con imágenes de medidores mecánicos, con etiquetas OBB para localizar el odómetro, lecturas enteras de referencia para entrenar y evaluar el OCR, y una partición estratificada para entrenamiento, validación y prueba.

- Diseñar una arquitectura modular que integre detección de odómetro, reconocimiento OCR y validación de lectura, con una latencia *end-to-end* p95 inferior a 4 segundos por imagen.

- Entrenar un detector de odómetro basado en YOLO OBB con mAP50-95 de al menos 0.90 para localizar de forma precisa la ventana de lectura, y un reconocedor OCR basado en PaddleOCR con *Exact Match Accuracy* de al menos 0.80 para leer correctamente los dígitos enteros del medidor.

- Implementar el *pipeline* completo y exponerlo mediante una API REST que devuelva la lectura extraída junto con una respuesta estructurada con estado e indicadores de confianza.

- Validar el sistema integrado en un piloto operativo con datos reales, alcanzando una coincidencia mínima del 80 % entre la lectura entera extraída por el sistema y la lectura de referencia, y documentar sus resultados, limitaciones y recomendaciones para su implementación operativa.

2. Marco teórico y estado del arte

2.1 Principales aportes de la literatura

La revisión bibliográfica confirma que la lectura automática de medidores mediante visión por computador se ha consolidado como una línea viable dentro de la digitalización del sector público. Zapata-Sierra et al. (2024) muestran que el campo de los medidores inteligentes ha crecido de forma sostenida y que la analítica basada en datos y aprendizaje automático ocupa un lugar cada vez más relevante. Dentro de este contexto, la literatura específica sobre lectura visual de medidores converge en una arquitectura recurrente: detección de la región de interés y reconocimiento posterior de la secuencia numérica.

La base de esta tendencia puede rastrearse hasta la familia YOLO, introducida por Redmon et al. (2016) como paradigma de detección en tiempo real. En el dominio de medidores de agua, Laroca et al. (2019) validan la utilidad de arquitecturas modulares para separar localización y reconocimiento, mientras que Gupta et al. (2024) y Hattak et al. (2023) muestran que variantes modernas de YOLO logran resultados competitivos en tareas de localización de display. Estos trabajos sugieren que la detección del odómetro suele ser una subtarea que se resuelve correctamente con modelos ligeros cuando el objeto está bien definido y las anotaciones son consistentes.

En reconocimiento óptico de caracteres, Li et al. (2022) presentan la familia PP-OCR como una alternativa eficiente para inferencia ligera, y van Nguyen et al. (2025) reportan que PaddleOCR ofrece un desempeño sólido frente a otros modelos OCR en lectura de medidores de agua. No obstante, estos mismos trabajos, junto con Chong et al. (2022), evidencian que el OCR sigue siendo sensible al dominio: reflejos, suciedad, inclinación, baja resolución y dígitos en transición afectan la lectura mucho más que la localización del display. En la misma línea, Dodge y Karam (2016) demuestran que ruido, compresión y desenfoque degradan significativamente el rendimiento de redes profundas.

Este hallazgo refuerza la relevancia de adaptar el pipeline a imágenes capturadas en campo, donde las condiciones visuales no siempre están controladas.

Un aporte relevante para este proyecto es el de Liang et al. (2022), quienes muestran que el reconocimiento automático puede utilizarse para asistir la validación de registros manuales. Aunque su propuesta no incorpora un mecanismo explícito de confianza ni priorización operativa, sí acerca la literatura al problema real de comparar la imagen con un valor ya digitado. Además, Martinelli et al. (2023) y Lall et al. (2022) refuerzan la idea de que estos sistemas pueden ser útiles incluso con hardware accesible, siempre que el diseño del pipeline sea pragmático y el entrenamiento aproveche transferencia de aprendizaje.

2.2 Tendencias, enfoques metodológicos y vacíos identificados

La principal tendencia observada es la superioridad práctica de los pipelines modulares sobre enfoques monolíticos. La separación entre detector y OCR permite optimizar cada componente por separado, interpretar mejor los errores y simplificar el mantenimiento del sistema. También se observa una transición desde modelos más grandes hacia configuraciones ligeras y desplegables, siempre que el dominio esté bien delimitado.

Una segunda tendencia es la importancia creciente de la adaptación al dominio. Los modelos OCR generalistas son un punto de partida útil, pero rara vez resuelven por sí solos el reconocimiento de odómetros mecánicos. La evidencia de van Nguyen et al. (2025), Chong et al. (2022) y Lall et al. (2022) indica que el desempeño real depende de ajustes específicos, como el vocabulario restringido, el preprocesamiento orientado al problema y el fine-tuning con datos del dominio.

Sin embargo, el vacío más relevante es metodológico y operativo. La mayoría de estudios reporta métricas de extracción técnica, pero pocos se enfocan en validar lecturas manuales dentro de un proceso de negocio. También es menos frecuente encontrar trabajos que documenten cómo decidir qué casos pasan a revisión humana y cómo mantener trazabilidad suficiente para auditoría. A esto se suma que gran parte de la literatura utiliza datasets privados o escenarios controlados, lo que dificulta extrapolar los resultados a condiciones reales de operación.

2.3 Relación con el problema abordado

El problema actual no exige reemplazar al operario con una lectura completamente autónoma, sino verificar si la evidencia fotográfica respalda el dato registrado. Por ello, la literatura revisada se traduce en cuatro decisiones de diseño concretas para este proyecto: usar un detector robusto y liviano para localizar el odómetro, adaptar el OCR al dominio de dígitos mecánicos, introducir preprocesamiento específico para reducir contaminación por decimales y mantener un flujo *human-in-the-loop* para los casos de baja confianza.

En este sentido, el proyecto se ubica en un punto intermedio entre la investigación académica y la necesidad organizacional, tomando de la literatura revisada los enfoques más consistentes para detección y reconocimiento, y reinterpretándolos bajo un enfoque de validación documental, trazabilidad y apoyo al proceso de auditoría.

3. Metodología

3.1 Diseño metodológico

El proyecto combinó dos marcos complementarios. Desde el punto de vista metodológico, se siguió CRISP-DM para estructurar el análisis y definición del problema, el entendimiento y preparación de los datos, el modelado, la evaluación y el despliegue (Chapman et al., 2000). Desde el punto de vista

de gestión, se utilizó Scrum para organizar la ejecución en 8 sprints de 2 semanas, revisar avances de forma periódica y ajustar decisiones técnicas según la evidencia obtenida en cada iteración.

En términos de gestión, el proyecto se estructuró en 8 sprints agrupados en siete fases: análisis, preparación, diseño, desarrollo, integración, evaluación y cierre.

Fase	Sprint(s)	Semanas	Propósito principal
Análisis	1	1-2	Comprender el problema de negocio, explorar los datos y definir métricas de éxito
Preparación	2	3-4	Limpiar los datos, anotar el dataset y construir los conjuntos de entrenamiento, validación y prueba
Diseño	3	5-6	Definir la arquitectura del pipeline y preparar el ambiente de desarrollo
Desarrollo	4-5	7-10	Entrenar y optimizar los componentes de detección y OCR
Integración	6	11-12	Integrar el pipeline completo y exponerlo como servicio
Evaluación	7	13-14	Ejecutar la evaluación end-to-end y la validación piloto
Cierre	8	15-16	Consolidar la documentación y preparar los entregables finales

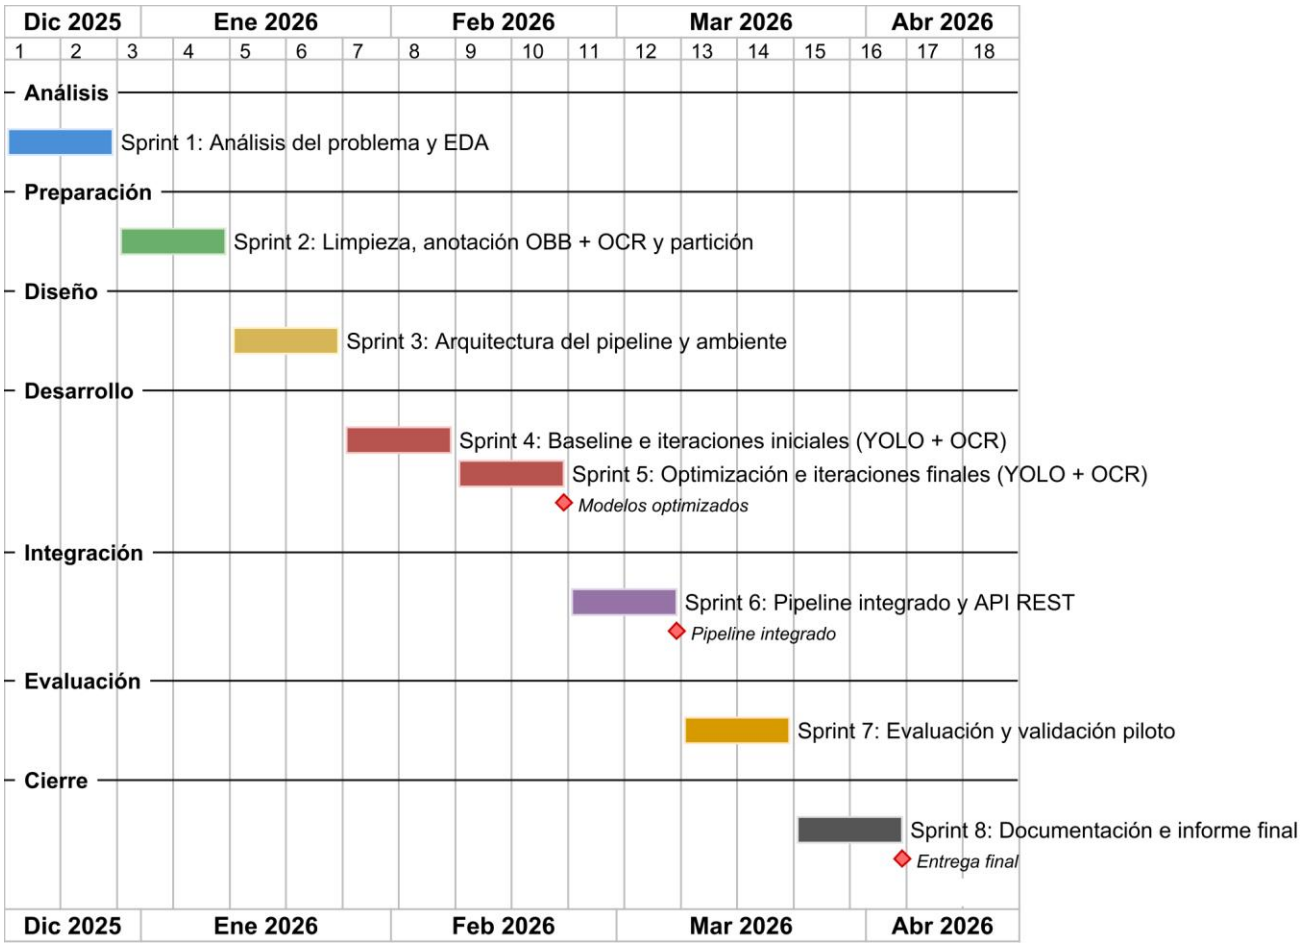

Figura 3. *Diagrama de Gantt del cronograma del proyecto.*

Desde la perspectiva metodológica, estas fases se alinearon con CRISP-DM de la siguiente manera: análisis con *Business Understanding* y *Data Understanding*; preparación con *Data Preparation*; desarrollo con *Modeling*; integración con *Deployment*; y evaluación con *Evaluation* complementada por la validación piloto. Las fases de diseño y cierre funcionaron como adaptaciones necesarias para llevar la metodología al contexto real del proyecto y completar la documentación académica y técnica.

Dentro de ese marco, el trabajo técnico priorizó primero la calidad de los datos y el control para evitar fuga de información entre entrenamiento, validación y prueba; luego la estabilización del componente de detección; y finalmente la optimización del OCR, que terminó siendo el principal cuello de botella de la solución.

3.2 Fuentes y preparación de datos

La fuente principal de datos fue un histórico de aproximadamente 3,200 imágenes operativas de medidores de agua, gestionado por SOLYTEC para una de las empresas de agua potable. Estas imágenes fueron clasificadas en tres grupos: válidas, ambiguas e inválidas. El dataset final del proyecto se construyó únicamente con las 1,199 imágenes válidas, ya que el objetivo inmediato era entrenar un validador sobre evidencia utilizable, no un clasificador general de calidad de captura.

El conjunto final contiene exclusivamente medidores mecánicos y presenta variaciones reales de orientación, fondo, cantidad de dígitos, presencia de decimales, suciedad, reflejos, obstrucciones parciales y condiciones de iluminación. Estas características lo vuelven representativo del entorno operativo, aunque también introducen desafíos importantes para el reconocimiento.

Sobre este conjunto se realizaron dos capas de anotación:

- Anotaciones OBB del odómetro para entrenar el detector.
- Transcripciones del valor entero visible para entrenar y evaluar el OCR.

El proceso de anotación para ambos componentes se realizó en CVAT. Para acelerar el proceso OBB se entrenó un modelo auxiliar con un subconjunto inicial cercano a 300 imágenes, cuyas predicciones fueron revisadas y corregidas manualmente antes de consolidar el dataset. La Figura 4 muestra un ejemplo de anotación OBB sobre un medidor.

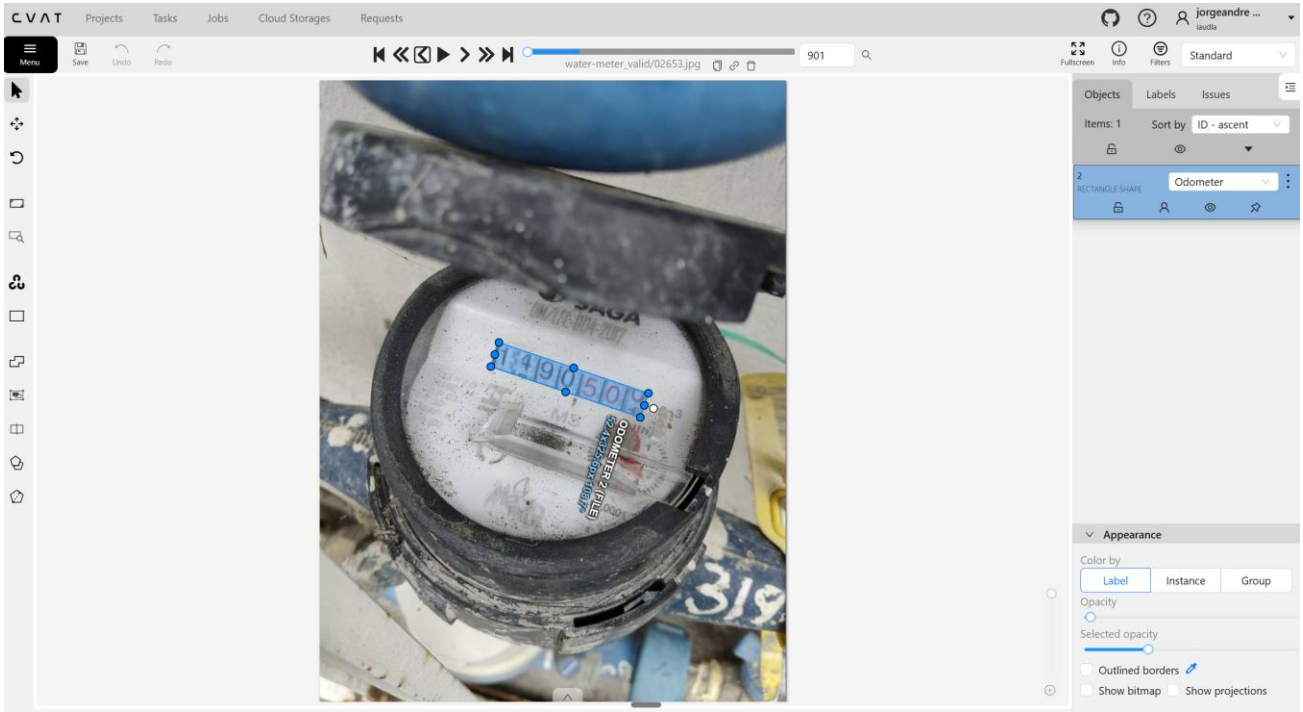

Figura 4. *Anotación de bounding box orientado (OBB) sobre un medidor en CVAT.*

La partición del dataset se fijó mediante un esquema hold-out estratificado 80/10/10, utilizando como variables de agrupación el color de fondo (*background*), el número de dígitos enteros (*n_digits*) y la presencia de decimales (*has_decimal*). El split final quedó establecido de la siguiente manera:

Split	Número de imágenes
Train	959
Validation	120
Test	120

Para evitar fuga de información (que el modelo vea durante el entrenamiento datos reservados para evaluación), los recortes OCR heredan el split de su imagen de origen. Así, ningún recorte de una imagen de prueba puede aparecer en el conjunto de entrenamiento.

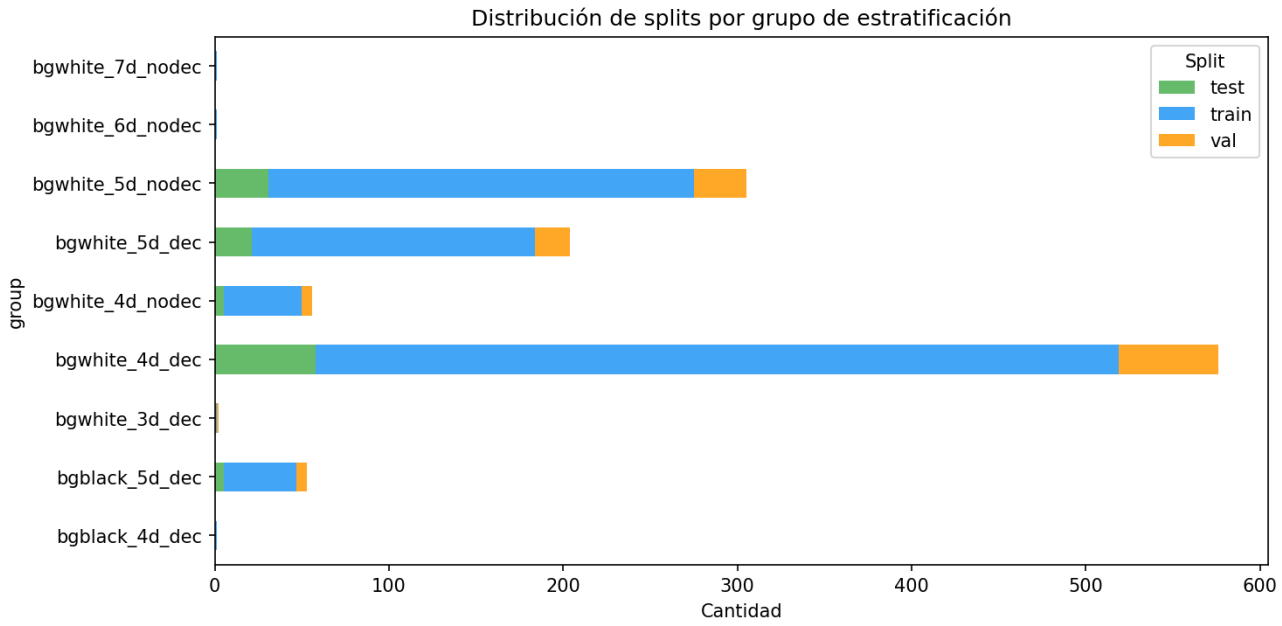

Figura 5. *Balance del split estratificado.*

La Figura 6 muestra la distribución del dataset válido por sus principales variables de caracterización: color de fondo, cantidad de dígitos enteros y presencia de decimales. Esta distribución fue la base para la estratificación del split y para el análisis de desempeño por subgrupos.

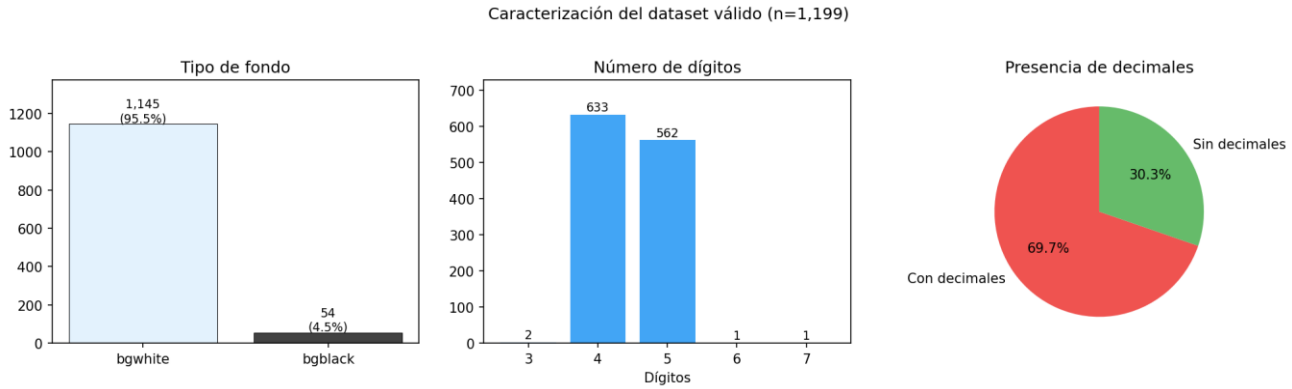

Figura 6. *Caracterización del dataset válido.*

3.3 Técnicas y modelos de IA utilizados

La solución adopta una arquitectura secuencial que incluye los siguientes componentes: detección del odómetro, preprocesamiento del recorte (corrección de orientación y enmascaramiento de dígitos decimales), reconocimiento OCR y un validador que clasifica cada caso según la confianza combinada del detector y del OCR. La implementación se desarrolló en Python, utilizando Ultralytics YOLO para detección OBB, PaddleOCR para reconocimiento, OpenCV para procesamiento de imágenes, CVAT para anotación, Jupyter Notebooks sobre Google Colab Pro para entrenamiento, análisis exploratorio y evaluación, y FastAPI para la integración del servicio a través de una API REST. La siguiente tabla resume la configuración final de cada componente.

Componente	Configuración vigente	Función
Detector	*yolov8n-obb*	Localizar el odómetro con cajas orientadas

OCR	*en_PP-OCRv4_mobile_rec* fine-tuned, solo reconicimiento (modo *rec-only*)	Leer la secuencia de dígitos enteros
Preprocesamiento	Corrección de orientación, máscara decimal LAB, sanitización digit-only	Reducir ruido visual y restringir la salida al dominio
Validador	Confianza global (producto de la confianza del detector y del OCR)	Clasificar cada caso como válido (*valid*), requiere revisión (*needs_review*) o sin detección (*no_detection*)

La elección de YOLO se apoya en la literatura de detección en tiempo real y en la evidencia empírica del proyecto. La elección de PaddleOCR se justifica por su eficiencia y por su buen desempeño reportado en lectura de medidores (Li et al., 2022; van Nguyen et al., 2025). Sin embargo, el reconocedor generalista no fue suficiente por sí solo; el desempeño aceptable solo se alcanzó tras omitir el detector de texto interno, cambiar a una variante optimizada para caracteres latinos (*english-only*) y realizar fine-tuning con diccionario restringido a dígitos.

Es importante señalar que el clasificador independiente de calidad de imagen, considerado en una etapa temprana del proyecto, dejó de formar parte del pipeline final. La experiencia acumulada mostró que la combinación de curación del dataset, preprocesamiento específico, OCR adaptado al dominio y revisión apoyada en niveles de confianza resolvía mejor el problema sin añadir complejidad innecesaria.

3.4 Consideraciones éticas y de sesgo

El proyecto se plantea como una herramienta de apoyo a auditoría y no como un sustituto total de la decisión humana. Esta premisa responde a consideraciones técnicas y éticas. Un error de lectura puede derivar en discrepancias de facturación o decisiones operativas difíciles de justificar si no existe trazabilidad suficiente.
Entre los principales riesgos identificados se encuentran el sesgo de representación del dataset, la subrepresentación de ciertos contextos visuales, la posible dependencia contextual del detector y la no calibración formal de la confianza global del pipeline. A esto se suman limitaciones inherentes al dominio, como lecturas ambiguas al rotar 180°, presencia de dígitos en transición y fallos ocasionales en el ocultamiento de decimales rojos.

Como estrategias de mitigación, el proyecto adopta cuatro criterios: anonimización de los datos operativos, trazabilidad de imagen original y recorte procesado, revisión humana de casos de baja confianza y documentación explícita de las limitaciones antes de cualquier despliegue.

4. Resultados preliminares

4.1 Descripción del prototipo desarrollado

El prototipo implementa los componentes descritos en la sección 3.3 y los expone como una API REST (FastAPI) consumible por la plataforma organizacional. La Figura 7 muestra la arquitectura de alto nivel: la aplicación móvil envía la imagen y la lectura digitada a la plataforma, esta invoca el pipeline, y el sistema devuelve una respuesta estructurada con la lectura estimada, la confianza global y el estado de validación.

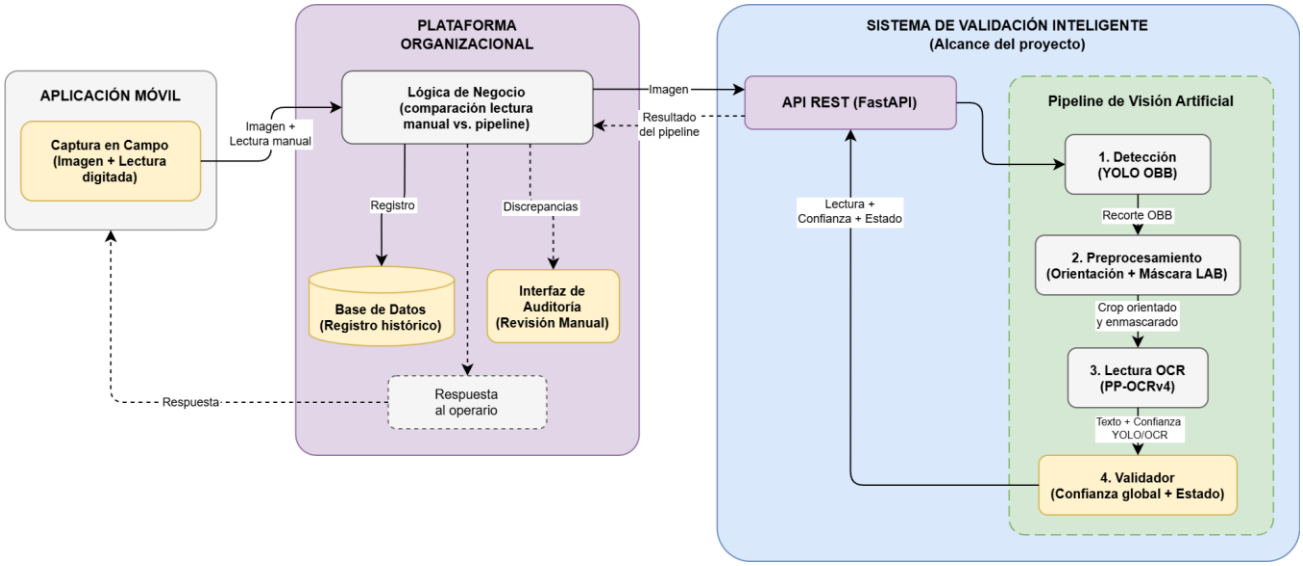

Figura 7. *Arquitectura de alto nivel del sistema.*

La Figura 8 detalla el flujo de decisión del validador. Este calcula una confianza global (producto de la confianza del detector y del OCR) y asigna uno de tres estados: válido (*valid*) cuando la confianza supera el umbral operativo de 0.7, requiere revisión (*needs_review*) cuando queda por debajo, o sin detección (*no_detection*) cuando el detector no localizó un odómetro en la imagen.

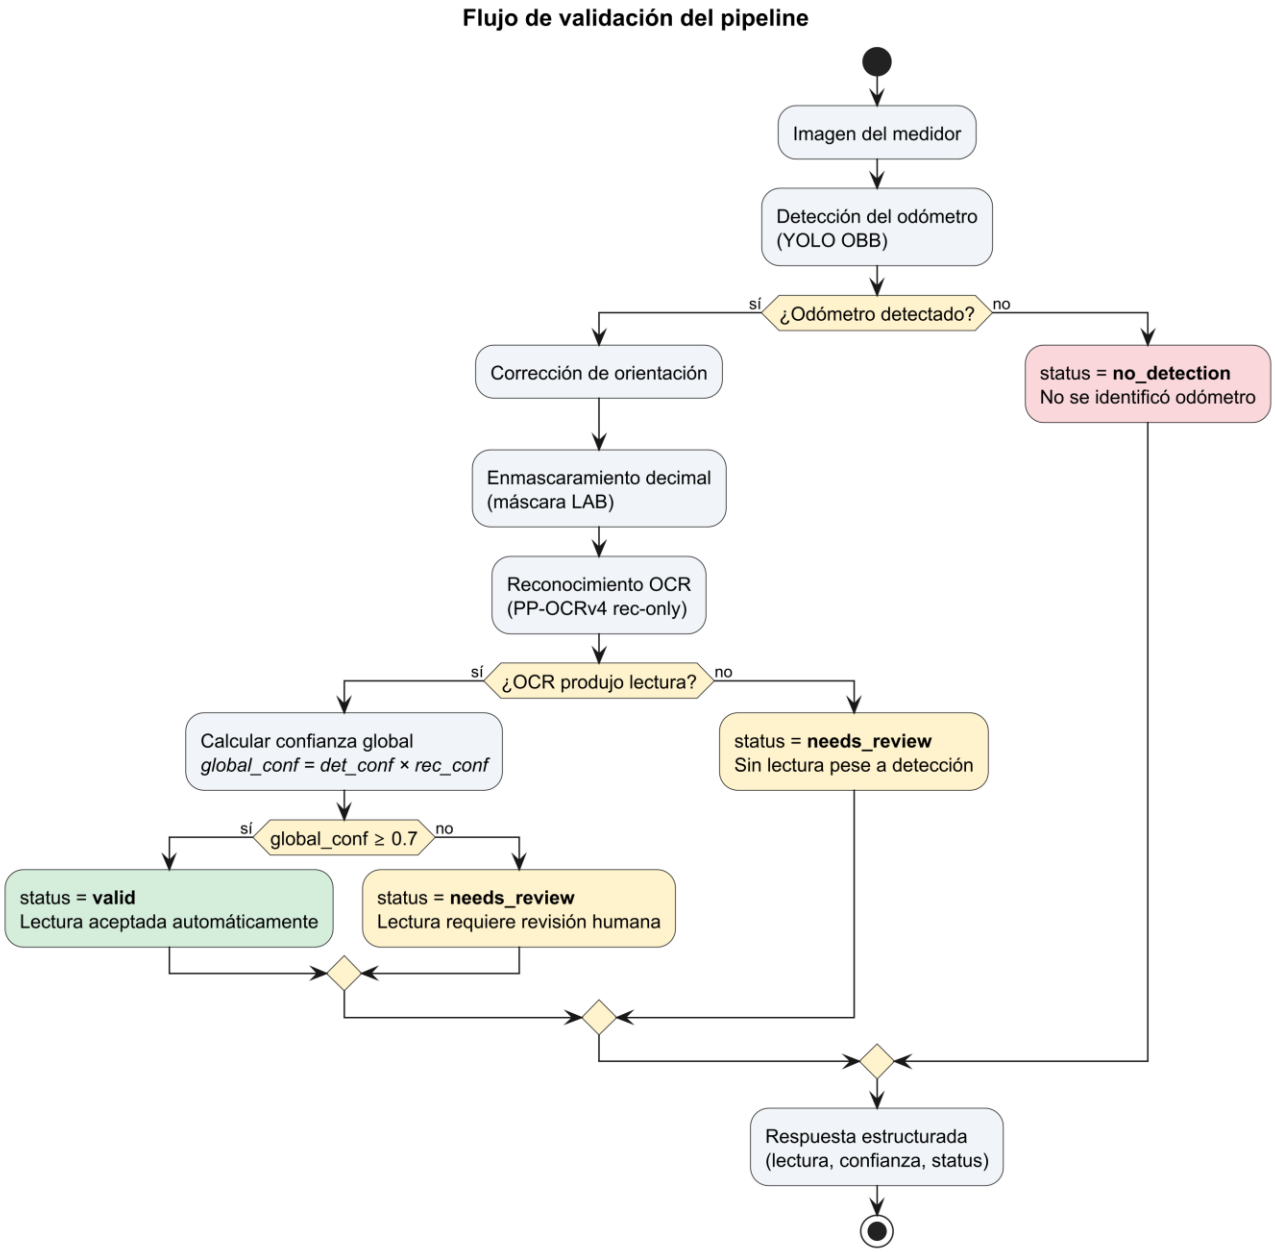

Figura 8. *Flujo de validación del pipeline (valid / needs_review / no_detection).*

Uno de los pasos de preprocesamiento más relevantes para el rendimiento del OCR es el enmascaramiento decimal. Los medidores mecánicos con ruedas decimales muestran dígitos rojos que el reconocedor puede confundir con dígitos enteros. La máscara LAB detecta estos píxeles y los reemplaza mediante inpainting, eliminando la señal visual antes de la lectura.

Figura 9. *Comparación del enmascaramiento decimal LAB antes y después del refinamiento.*

Adicionalmente, se implementó una interfaz de demostración con Gradio (Figura 10) que permite visualizar en tiempo real la detección, el recorte, el enmascaramiento y la lectura OCR resultante. Esta herramienta sirvió como validación funcional del flujo completo durante el desarrollo.

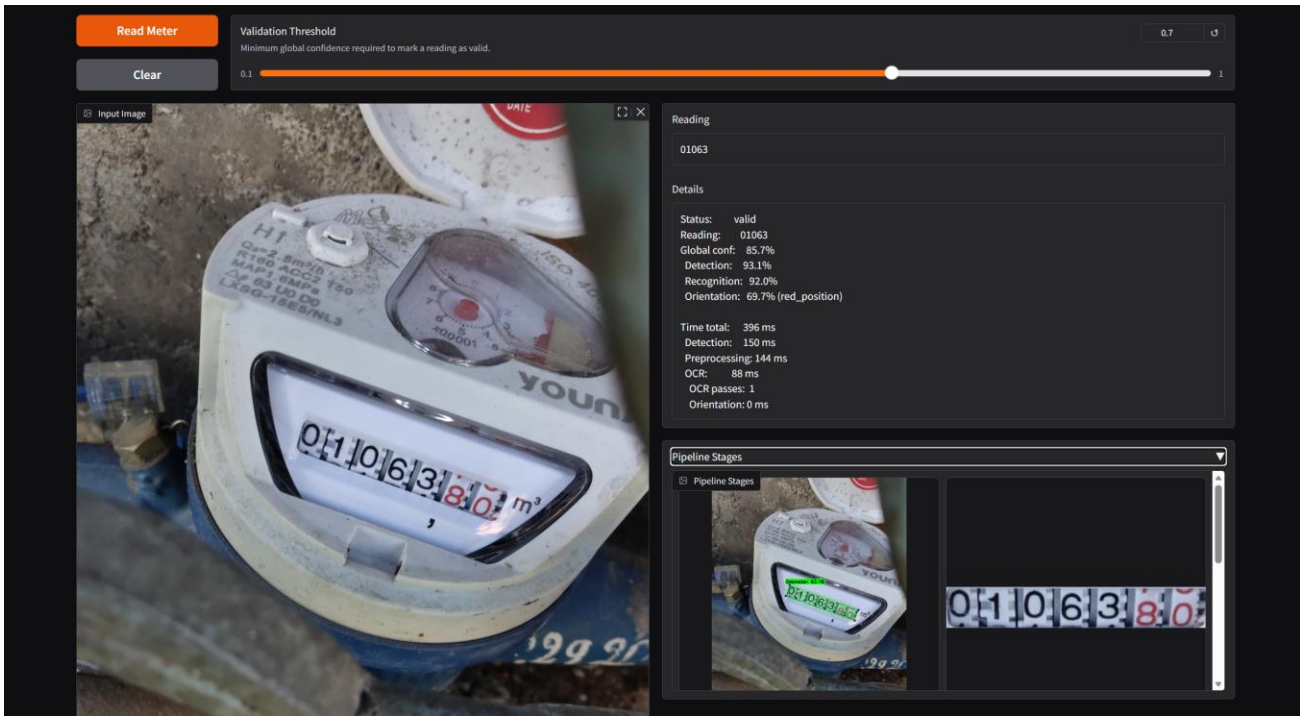

Figura 10. *Interfaz de demostración del pipeline integrado.*

4.2 Resultados obtenidos

Detector de odómetro

La configuración con mejor desempeño del detector fue el baseline *yolov8n-obb* con resolución de 640 píxeles, 100 épocas de entrenamiento, lotes de 16 imágenes y paciencia de 50 épocas para early stopping. Ninguna de las cinco iteraciones posteriores superó esa línea base.

Métrica	Valor en test
mAP50-95	**0.9522**
mAP50	**0.9950**
Precision	0.9920
Recall	1.0000

Con estos valores, la detección del odómetro presenta un desempeño alto y estable dentro del dataset disponible. El Recall perfecto indica que el modelo no dejó de detectar ningún odómetro en prueba, y la diferencia restante frente a un mAP50-95 perfecto se concentra en la localización fina a umbrales de IoU más exigentes, no en fallos de detección.

OCR

La configuración con mejor desempeño del lector OCR fue *en_PP-OCRv4_mobile_rec* fine-tuned, en modo *rec-only*, con diccionario restringido a dígitos y dataset generado con máscara LAB para ocultar decimales. Esta versión corresponde a la última iteración, donde se entrenó el OCR sobre los crops de odómetro tras refinar el algoritmo de enmascaramiento decimal.

Métrica	Valor en test
Exact Match Accuracy	**0.9250 (111/120)**
CER	**0.0186**
CRR	0.9814
EM con decimales	0.9405 (79/84)
EM sin decimales	0.8889 (32/36)
Tiempo promedio OCR	9 ms/imagen

El OCR fue el componente con mayor variación entre iteraciones y el principal cuello de botella del proyecto. El baseline, con crops sin máscara y sin adaptación al dominio, tuvo un rendimiento muy bajo. La configuración final superó ampliamente la meta de 80% de coincidencia exacta, y la mejora se concentró especialmente en la lectura de medidores con decimales.

Hito del OCR	Exact Match Accuracy
P0 - raw crops sin máscara	0.0083 (val)
Iter 1 - *det-bypass*	0.1583 (val)
Iter 3 - *PP-OCRv4 english-only*	0.3000 (val)
Iter 4 - fine-tuning digit-only	0.9000 (val) / 0.8750 (test)
Iter 6 - fine-tuning con máscara LAB refinada	0.8917 (val) / 0.9250 (test)

Al comparar la Iteración 4 y la Iteración 6, se observa que en validación el desempeño se mantuvo en niveles muy similares, con una diferencia de apenas una muestra (0.9000 frente a 0.8917). Sin embargo, al pasar al conjunto de prueba, la Iteración 6 demostró una clara superioridad al alcanzar un 0.9250 (111/120) frente al 0.8750 (105/120) de la Iteración 4. Esta mejora se concentró en el

subconjunto de medidores con decimales, donde el Exact Match Accuracy subió significativamente de 0.8690 a 0.9405. Esta mejora de precisión en los casos con decimales fue el factor decisivo para seleccionar la Iteración 6 como la configuración final del modelo OCR.

Evaluación end-to-end

La evaluación end-to-end ejecutó el pipeline completo sobre las 120 imágenes del conjunto de prueba, incluyendo detección, orientación, enmascaramiento y OCR. La métrica principal fue la coincidencia entre la lectura normalizada (sin ceros a la izquierda) y la referencia anotada.

Métrica	Valor
Tasa de coincidencia (*match rate* / *accuracy*)	95.83% (115/120)
Tasa de lectura (*readable rate*)	100.00%
Tasa de validación automática (*auto-validation rate*)	93.33%
Precisión de validación automática (*auto-validation precision*)	96.43%
Latencia media por imagen	435 ms

El resultado end-to-end supera la meta del proyecto (80%) y al OCR aislado (92.50%) gracias a que la comparación normalizada tolera diferencias de padding (ver Anexo A.3 para el detalle por subgrupos). De los 5 errores, 2 involucran orientación ambigua y 3 corresponden al patrón de omisión de dígitos ya identificado en el análisis de explicabilidad. El subgrupo de medidores sin decimales mantiene una tasa de coincidencia inferior (91.67%) a la de medidores con decimales (97.62%), consistente con el sesgo de posición documentado.

Validación piloto

La validación piloto evaluó el pipeline sobre 300 imágenes capturadas por lectores en campo, comparando la lectura del sistema con el valor digitado manualmente.

Métrica	Valor
Tasa de coincidencia (*match rate* / *accuracy*)	82.67% (248/300)
Tasa de lectura (*readable rate*)	92.67%
Tasa de validación automática (*auto-validation rate*)	83.33%
Precisión de validación automática (*auto-validation precision*)	90.40%
Tasa de no-detección (*no-detection rate*)	6.67% (20/300)
Latencia media por imagen	1153 ms

De las 20 imágenes sin detección, 14 no contienen un medidor con odómetro legible (12 fotografías sin medidor y 2 con display ilegible por obstrucción o empañamiento extremo). Las 6 restantes corresponden a fallos reales del detector: 4 por condiciones adversas de imagen (suciedad, inclinación, odómetro poco claro) y 2 por modelos de medidor subrepresentados en el conjunto de entrenamiento. En los 14 casos no procesables el sistema no emitió lectura ni generó falsos positivos. El Anexo A.4 presenta la clasificación completa con ejemplos visuales de cada categoría. Sobre las 286 imágenes con medidor procesable, la tasa de coincidencia es de **86.71%** (248/286).
La revisión visual de los 32 errores de lectura (30 predicciones incorrectas y 2 casos sin lectura pese a detectar el odómetro) reveló cinco causas principales: omisión de dígitos (14 casos), calidad visual

degradada del medidor (7 casos), orientación ambigua de la imagen (4 casos), imágenes rotadas o inclinadas por la posición incómoda del medidor (3 casos) y errores del propio operario al capturar la imagen o digitar la lectura (2 casos). El Anexo A.4 presenta la clasificación completa con ejemplos representativos.

La brecha entre el entorno controlado (95.83%) y el operativo (82.67%) refleja la variabilidad de las condiciones de campo. La tasa de auto-validación incorrecta (9.60%) indica que el umbral actual no filtra errores con la misma eficacia sobre datos operativos, lo que refuerza la necesidad de mantener revisión humana en los despliegues iniciales.

Análisis del umbral de validación

Para evaluar el punto de operación del validador se ejecutó una validación de umbrales sobre los resultados de ambas evaluaciones. La siguiente tabla resume el tradeoff entre autonomía del sistema y tasa de error para los umbrales más relevantes:

Umbral	Validación automática (test)	Precisión (test)	Errores auto-validados (test)	Validación automática (piloto)	Precisión (piloto)	Errores auto-validados (piloto)
0.60	100.00%	95.83%	5	89.67%	89.96%	27
0.65	100.00%	95.83%	5	88.00%	90.15%	26
0.70	**93.33%**	**96.43%**	**4**	**83.33%**	**90.40%**	**24**
0.75	85.00%	98.04%	2	70.33%	91.47%	18
0.80	60.00%	100.00%	0	53.33%	90.62%	15

En el conjunto de test, el umbral de 0.7 ofrece un equilibrio razonable: el 93% de los casos se resuelven automáticamente con una precisión del 96.43% (4 errores en 112 validaciones). Subir a 0.75 reduce los errores a 2 pero envía un 15% de los casos a revisión; a 0.80 se eliminan todos los errores auto-validados pero el 40% requiere revisión manual.

En el piloto, la precisión de auto-validación se mantiene entre 90% y 91% para umbrales de 0.60 a 0.80, lo que indica que subir el umbral no mejora sustancialmente la precisión en datos operativos sino que principalmente reduce la cobertura automática. Con el umbral actual de 0.7, el 83% de los casos se valida automáticamente con un 90.40% de precisión. Esto confirma que el umbral de 0.7 ofrece el mejor equilibrio entre cobertura automática y precisión para el contexto operativo actual (ver Anexo B.1 para la barrida completa).

4.3 Análisis del desempeño del modelo

El desempeño del sistema presenta un contraste claro entre sus dos componentes principales (ver Anexos A.1 y A.2 para la evolución completa de iteraciones). El detector alcanzó su mejor resultado con la configuración baseline y ninguna de las cinco iteraciones posteriores (con mayor resolución, arquitecturas más grandes o más épocas de entrenamiento) logró superarlo. Este resultado sugiere que, para una tarea de una sola clase con anotaciones consistentes, un modelo ligero es suficiente.

El OCR fue el componente que concentró los mayores desafíos técnicos y donde se ejecutaron las iteraciones de mejora más críticas del proyecto. La evolución del rendimiento no dependió de implementar modelos de mayor escala, sino de una serie de decisiones técnicas orientadas específicamente al dominio del problema. Entre estas destacan la omisión del detector interno de

PaddleOCR por redundancia, la transición a una variante *english-only* optimizada para lectura numérica, la aplicación de fine-tuning con un diccionario restringido a dígitos y el refinamiento del enmascaramiento decimal para normalizar la entrada al reconocedor. En conjunto, el control riguroso de los datos de entrada y la especialización del modelo demostraron ser factores mucho más determinantes que cambios en la complejidad arquitectónica.

El análisis de errores sobre la última iteración en el conjunto de prueba revela que los fallos restantes se distribuyen en tres categorías: omisión de dígitos (66.7%), dígitos adicionales o espurios (22.2%), y sustitución de dígitos (11.1%). El patrón dominante es la pérdida de una cifra, y el análisis de explicabilidad (Grad-CAM + oclusión) permitió identificar su causa raíz: un sesgo de posición inducido por la distribución del dataset de entrenamiento. Al estar compuesto en un 70% por medidores con decimales donde la máscara deja las últimas posiciones vacías, el modelo aprendió a desatender las posiciones finales del odómetro de forma generalizada, afectando también a los medidores con solo dígitos enteros.

La validación piloto confirmó que la omisión de dígitos sigue siendo el error dominante también en condiciones operativas (14 de 32 errores de lectura). A este patrón se suman causas propias del entorno de campo que no se manifiestan en el conjunto de prueba controlado: calidad visual degradada de los medidores, orientación ambigua de las imágenes e imágenes tomadas en posiciones incómodas con inclinación pronunciada.

5. Validación e interpretabilidad

5.1 Técnicas de validación aplicadas

La validación del proyecto se sostuvo sobre un esquema hold-out estratificado 80/10/10, con el conjunto de prueba reservado para una sola evaluación final por componente y para la medición del pipeline integrado. Todas las decisiones de ajuste se tomaron exclusivamente sobre el conjunto de validación, de modo que el conjunto de prueba se mantuviera libre de contaminación y los subgrupos minoritarios quedaran representados en cada split.

Para comparar las iteraciones de cada modelo, se adoptaron criterios adaptados al tamaño del dataset. En el detector, diferencias menores a 0.5 puntos porcentuales en mAP50-95 no se consideraron mejoras reales, dado que con 120 imágenes de validación cualquier variación inferior a ese umbral podía confundirse con ruido del muestreo. En el OCR se aplicó una lógica similar: se valoró la magnitud de los cambios, pero siempre acompañada del análisis de errores y del comportamiento cualitativo del pipeline, ya que una mejora pequeña en accuracy no necesariamente justificaba cambiar de configuración si el patrón de fallos seguía siendo el mismo.

Una vez estabilizados ambos componentes, el proyecto definió dos niveles adicionales de evidencia: la evaluación end-to-end sobre el conjunto de test, orientada a observar cómo interactúan el detector y el OCR de forma objetiva y sin sesgos de datos previos, y la validación piloto con casos operativos, en un entorno más cercano al proceso real de auditoría. Ambas fases se ejecutaron con la configuración final del OCR (Iter 6) y sus resultados se detallan en la sección 4.2.

5.2 Análisis de interpretabilidad (XAI)

El análisis de interpretabilidad se orientó a verificar si los modelos atienden a las regiones relevantes de la imagen o si parte de su desempeño depende de señales del contexto visual circundante.
En el detector YOLO se aplicó Eigen-CAM complementado con oclusión condicionada. Los mapas de activación se concentraron en la ventana numérica y en la cara frontal del medidor, con un *focus ratio* medio de **1.04**, lo que indica que la atención del modelo se distribuye dentro del odómetro más que en el fondo. La correlación entre los mapas y la caída real de confianza al ocluir regiones relevantes fue positiva en la mayoría de los casos analizados, con valores entre **0.58** y **0.69**. Sin

embargo, se identificó un caso con correlación de **-0.32**, que evidencia una dependencia parcial del contexto visual en escenarios puntuales.

[notebooks/06_explainability_reports/yolo_eigencam_grid_part1.png]
Figura 11. *Mapas Eigen-CAM del detector YOLO sobre muestras representativas.*

En el OCR se aplicó Grad-CAM ponderado por probabilidad a nivel de carácter, complementado con oclusión por bandas verticales. El análisis reveló un patrón de enfriamiento sistemático en las posiciones finales del odómetro: el modelo concentra su activación en las primeras posiciones del display y la atenúa progresivamente hacia el final, tanto en medidores con decimales enmascarados como en medidores con solo dígitos enteros.

Este patrón se explica por la composición del dataset de entrenamiento: aproximadamente el 70% de las muestras corresponde a medidores con decimales, donde la máscara LAB deja las posiciones finales vacías. El modelo internalizó esta distribución como un patrón general de omisión de las últimas posiciones, lo que afecta al subgrupo minoritario de medidores enteros. La oclusión por bandas verticales confirmó este hallazgo: la correlación entre Grad-CAM y caída real de probabilidad fue de **0.87** en el mejor caso (predicción correcta), **0.56** en el caso mediano, y **0.10** en un caso de error donde el modelo omitió el último dígito. Se observó además un caso donde el OCR interpretó la separación física entre ruedas del odómetro como un dígito, evidenciando una activación intensa del heatmap sobre ese elemento estructural (ver Anexo C.3 para el análisis completo del sesgo de posición).

[notebooks/06_explainability_reports/ocr_gradcam_grid_part1.png]
Figura 12. *Mapas Grad-CAM del OCR sobre muestras representativas.*

La Figura 13 ilustra un caso concreto de este patrón: la muestra 00233 (referencia "01826", predicción "0182"). A la izquierda, el mapa Grad-CAM muestra activación concentrada en las primeras cuatro posiciones y enfriamiento en la quinta. A la derecha, la oclusión por bandas confirma que cubrir las posiciones finales apenas afecta la predicción, mientras que cubrir las primeras posiciones la altera significativamente.

[notebooks/06_explainability_reports/occlusion_compare_00233.png]
Figura 13. *Comparación Grad-CAM vs. oclusión en caso de error por omisión de dígito final (predicción "0182" vs. referencia "01826").*

5.3 Pruebas de robustez realizadas

La robustez del sistema se evaluó mediante la comparación sistemática de configuraciones, el análisis de errores y la revisión de casos difíciles en distintos escenarios. En detección se probaron cambios de resolución, escalado de arquitectura, data augmentation y criterios de convergencia; en OCR se compararon *raw crops* contra máscaras HSV y LAB, la inclusión o exclusión del detector de texto interno, las variantes *mobile* y *server* del reconocedor, y el efecto del fine-tuning. Este recorrido permitió identificar qué configuración funcionaba mejor y bajo qué condiciones aparecía cada mejora. El patrón que emerge de estas pruebas es consistente: la estabilidad del sistema no depende de añadir complejidad indiscriminadamente, sino de controlar con precisión la entrada al OCR y mantener un pipeline coherente con el dominio. La máscara decimal, la corrección de orientación y la restricción del vocabulario son parte integral de esa estabilidad. La validación piloto confirmó este comportamiento: la brecha de rendimiento entre el entorno controlado y el operativo se concentra en el reconocimiento de dígitos (omisión, calidad visual, orientación) y no en la detección (ver Anexos B.2–B.4 para el detalle de cada prueba).

5.4 Riesgos identificados y estrategias de mitigación

Los principales riesgos técnicos y éticos identificados se agrupan en seis frentes. El dataset no cubre todos los modelos de medidor ni todos los contextos visuales que podrían presentarse en operación. Algunas lecturas son inherentemente ambiguas, ya sea porque el odómetro se encuentra en transición entre dígitos o porque la imagen admite interpretaciones válidas en rotaciones de 180°. El análisis XAI reveló que, en escenarios aislados, el detector depende parcialmente del contexto visual y no exclusivamente del contenido del display. El desbalance entre subgrupos en el dataset de entrenamiento (70% medidores con decimales, 30% solo enteros) indujo un sesgo de posición en el OCR que afecta desproporcionadamente al subgrupo minoritario, lo cual fue identificado específicamente mediante el análisis de explicabilidad. La confianza global (*global_confidence*) utilizada en la clasificación operativa no ha sido calibrada formalmente como probabilidad de corrección. A estos riesgos técnicos se suma uno de gobernanza: que el buen desempeño global se interprete como justificación para automatizar decisiones sin mantener supervisión humana.

Las estrategias de mitigación propuestas son coherentes con el contexto del problema. En primer lugar, se recomienda mantener un esquema *human-in-the-loop* donde la salida del modelo apoye y priorice la revisión, pero no reemplace la decisión humana en los casos ambiguos. En segundo lugar, conviene preservar trazabilidad completa (imagen original, recorte, predicción y confianza) para poder auditar cualquier discrepancia entre la lectura extraída y la lectura digitada. En tercer lugar, el sesgo de posición identificado por XAI sugiere que una línea prioritaria de mejora es aumentar la proporción de muestras de medidores con solo dígitos enteros en el dataset de entrenamiento y reentrenar el modelo. Por su parte, la validación de umbrales confirma que el valor actual (0.7) ofrece el mejor equilibrio entre cobertura automática y precisión. Por último, el sistema debe seguir mejorando a partir de la expansión progresiva del dataset, la auditoría periódica mediante XAI y la revisión sistemática de los casos que hoy terminan clasificados como pendientes de revisión o sin detección.

6. Conclusiones preliminares, implicaciones y trabajo futuro

Los resultados obtenidos muestran viabilidad técnica y un nivel funcional suficiente para respaldar una validación asistida de lecturas de medidores. La detección del odómetro alcanzó un desempeño estable con una configuración ligera, mientras que el OCR demostró que el rendimiento útil aparece cuando el problema se aborda bajo las restricciones específicas del entorno operativo y no como un caso genérico de reconocimiento de texto.

El aporte central del proyecto está en haber cerrado con evidencia sólida el sistema completo. El detector alcanzó un **mAP50-95 de 0.9522** en el conjunto de prueba, el OCR cerró con **92.50% de *Exact Match Accuracy*** tras la iteración 6 y la máscara LAB refinada, y el pipeline integrado alcanzó un **95.83% de exactitud end-to-end** sobre el mismo conjunto. La validación piloto con 300 imágenes operativas obtuvo una **tasa de coincidencia del 82.67%** sobre el total de imágenes, superando la meta del proyecto (80%). Del 6.67% de imágenes donde el sistema no emitió lectura, el 4.67% correspondió a fotografías que no contenían un medidor con odómetro procesable o legible (fachadas, tapas cerradas, displays con obstrucción o empañamiento extremo), en las cuales el sistema gestionó correctamente la situación sin generar falsos positivos. Si se aísla el desempeño sobre las imágenes que contienen un medidor con display numérico, la tasa de coincidencia sube a **86.71%**. Esta distinción confirma la viabilidad del sistema en condiciones reales, aunque la brecha respecto al entorno controlado señala el camino para futuras mejoras.

Más allá de las métricas obtenidas, estos resultados validan un enfoque metodológico que trasciende este caso particular. En el despliegue de soluciones de visión artificial aplicadas a entornos operativos, queda demostrado que el valor estratégico no radica únicamente en la adopción del modelo más robusto o reciente, sino en construir un pipeline coherente con el dominio, cuidar la

calidad de los datos y mantener una lógica de integración que garantice decisiones por el sistema que puedan ser interpretables. El análisis de explicabilidad demostró además que el preprocesamiento puede inducir sesgos no previstos: la máscara decimal, aunque mejora el rendimiento global, generó un sesgo de posición en el modelo que solo se hizo visible mediante la inspección combinada de Grad-CAM y oclusión. Este hallazgo refuerza que la explicabilidad no es un requisito formal secundario, sino una herramienta práctica para identificar oportunidades de mejora que las métricas agregadas no revelan.

A partir de estos resultados, se identifican las siguientes líneas de trabajo futuro, ordenadas por impacto esperado:

- Aumentar la proporción de muestras de medidores con solo dígitos enteros en el dataset de entrenamiento para corregir el sesgo de posición identificado por el análisis de explicabilidad y mejorar el rendimiento del subgrupo actualmente afectado (88.89% vs. 94.05% en medidores con decimales).
- Incorporar imágenes del piloto al dataset de entrenamiento para cerrar la brecha entre el entorno controlado (95.83%) y el operativo (82.67%), exponiendo al modelo a las condiciones reales de campo: medidores sucios, empañados, parcialmente obstruidos e imágenes con inclinación pronunciada.
- Mejorar el módulo de orientación, dado que 4 de los 32 errores del piloto se debieron a orientación ambigua y 3 adicionales a imágenes muy rotadas o inclinadas. Esto incluye evaluar estrategias más robustas para resolver la ambigüedad 0°/180° cuando el método dual-OCR no logra distinguir la orientación correcta.
- Explorar la integración del sistema en tiempo real dentro del flujo de captura, permitiendo que la herramienta asista al operario de manera inmediata tras la toma de la fotografía y asegure la calidad de la lectura.

7. Referencias

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS Inc.

Chong, Y. J., Huat Chua, K., Babrdel, M., Hau, L. C., & Wang, L. (2022). *Deep Learning and Optical Character Recognition for Digitization of Meter Reading*. 2022 12th IEEE Symposium on Computer Applications and Industrial Electronics, 7-12. https://doi.org/10.1109/ISCAIE54458.2022.9794463

Dodge, S., & Karam, L. (2016). *Understanding how image quality affects deep neural networks*. 8th International Conference on Quality of Multimedia Experience. https://doi.org/10.1109/QoMEX.2016.7498955

Gupta, H., Jaiswal, A., Yadav, P., & Gupta, N. (2024). *Deep Learning Based Automated Electronic Meter Reading System using YOLOv5 Architecture*. Proceedings of the 2023 International Conference on Big Data Mining and Information Processing, 45-53. https://doi.org/10.1145/3645279.3645288

Hattak, A., Iadarola, G., Martinelli, F., Mercaldo, F., & Santone, A. (2023). *Benchmarking YOLO Models for Automatic Reading in Smart Metering Systems: A Performance Comparison Analysis*. 2023 International Conference on Machine Learning and Applications, 2207-2213. https://doi.org/10.1109/ICMLA58977.2023.00333

Lall, A. K., Khandelwal, A., Nilesh, N., & Chaudhari, S. (2022). *Improving IoT-based Smart Retrofit Model for Analog Water Meters using DL based Algorithm*. 2022 9th International Conference on Future Internet of Things and Cloud, 207-212. https://doi.org/10.1109/FiCloud57274.2022.00035

Laroca, R., Barroso, V., Diniz, M. A., Gonçalves, G. R., Schwartz, W. R., & Menotti, D. (2019). *Convolutional neural networks for automatic meter reading*. *Journal of Electronic Imaging, 28*(1), 013023. https://doi.org/10.1117/1.JEI.28.1.013023

Li, C., Liu, W., Guo, R., Yin, X., Jiang, K., Du, Yongkun, Du, Yuning, Zhu, L., Lai, B., Hu, X., Yu, D., & Ma, Y. (2022). *PP-OCRv3: More attempts for the improvement of ultra lightweight OCR system*. arXiv. http://arxiv.org/abs/2206.03001

Liang, Y., Liao, Y., Li, S., Wu, W., Qiu, T., & Zhang, W. (2022). *Research on water meter reading recognition based on deep learning*. *Scientific Reports, 12*(1), 12861. https://doi.org/10.1038/s41598-022-17255-3

Martinelli, F., Mercaldo, F., & Santone, A. (2023). *Water Meter Reading for Smart Grid Monitoring*. *Sensors, 23*(1), 75. https://doi.org/10.3390/s23010075

Muhammad, M. B., & Yeasin, M. (2020). *Eigen-CAM: Class Activation Map using Principal Components*. 2020 International Joint Conference on Neural Networks. https://doi.org/10.1109/IJCNN48605.2020.9206626

Redmon, J., Divvala, S., Girshick, R., & Farhadi, A. (2016). *You Only Look Once, Real-Time Object Detection*. 2016 IEEE Conference on Computer Vision and Pattern Recognition, 779-788. https://doi.org/10.1109/CVPR.2016.91

Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. (2020). *Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization*. *International Journal of Computer Vision, 128*(2), 336-359. https://doi.org/10.1007/s11263-019-01228-7

van Nguyen, B., Nguyen, A., Tran-Trung, K., Ho Huong, T., Duong Thi Hong, H., Nguyen Trung, H., & Truong Hoang, V. (2025). *Water Meter Reading Based on Text Recognition Techniques and Deep Learning*. *IEEE Access, 13*, 41422-41434. https://doi.org/10.1109/ACCESS.2025.3547225

Zapata-Sierra, A. J., Salmerón-Manzano, E., Alcayde, A., Zapata-Castillo, M. L., & Manzano-Agugliaro, F. (2024). *The Scientific Landscape of Smart Water Meters: A Comprehensive Review*. *Water, 16*(1), 113. https://doi.org/10.3390/w16010113