Maestría en Inteligencia Artificial Aplicada

TTMZ0055 – Proyecto MIA

S9: ANEXOS DE VALIDACIÓN

Integrantes:

Jorge Andrés Padilla

Alain Mateo Ruales

Marzo 2026

Tabla de Contenido

Tabla de Contenido 2
Anexo A - Evidencia de validación del modelo 3
A.1 Evolución del detector (YOLO OBB) 3
A.2 Evolución del OCR (PP-OCRv4) 5
A.3 Evaluación end-to-end 6
A.4 Validación piloto 8
Anexo B - Análisis de robustez 12
B.1 Sensibilidad al umbral de validación 12
B.2 Sensibilidad al preprocesamiento: efecto de la máscara decimal 13
B.3 Sensibilidad a la orientación 13
B.4 Comportamiento frente a datos fuera de dominio 14
Anexo C - Interpretación técnica de los resultados 14
C.1 Confiabilidad y consistencia del modelo 14
C.2 Respaldo de las decisiones metodológicas 15
C.3 Hallazgos principales 15
C.4 Relación con los objetivos del proyecto 16

Anexo A - Evidencia de validación del modelo

Este anexo presenta las evidencias cuantitativas de los tres niveles de validación ejecutados: evaluación por componente (detector y OCR), evaluación end-to-end sobre el conjunto de prueba y validación piloto con datos operativos.

A.1 Evolución del detector (YOLO OBB)

El detector se evaluó mediante un proceso iterativo de seis configuraciones. La Tabla A.1 resume los resultados sobre el conjunto de validación (120 imágenes). Las métricas utilizadas son:

- **mAP50-95:** promedio de precisión media evaluado en umbrales de IoU (intersección sobre la unión, es decir, qué tanto se solapan el área predicha y la anotada) desde 0.50 hasta 0.95, el cual penaliza localizaciones imprecisas. Métrica principal del detector YOLO.
- **mAP50:** precisión media a un umbral de IoU de 0.50. Criterio más permisivo que mAP50-95.
- **Precision:** proporción de detecciones que corresponden a un odómetro real (penaliza falsos positivos).
- **Recall:** proporción de odómetros reales que fueron detectados (penaliza falsos negativos).
- **delta vs baseline:** diferencia en puntos porcentuales respecto al baseline.
- **delta vs mejor:** diferencia en puntos porcentuales respecto a la última iteración adoptada.

Tabla A.1. *Comparación de iteraciones del detector YOLO OBB sobre el conjunto de validación.*

Iteración	Configuración principal	mAP50-95	mAP50	Precision	Recall	delta vs baseline	delta vs mejor	Decisión
Baseline	yolov8n-obb, 640px, 100 épocas	0.9609	0.9950	0.9995	1.0000	-	-	**Adoptado**
Iter 1	Resolución 1280px	0.9556	0.9950	0.9995	1.0000	−0.53 pp	−0.53 pp	Revertido
Iter 2	yolov8s-obb (small)	0.9574	0.9950	0.9991	1.0000	−0.35 pp	−0.35 pp	Revertido
Iter 3	yolo11n-obb (architecture upgrade)	0.9621	0.9950	0.9992	1.0000	+0.12 pp	+0.12 pp	Revertido
Iter 4	Augmentación copy-paste, 200 épocas	0.9519	0.9950	0.9995	1.0000	−0.90 pp	−0.90 pp	Revertido
Iter 5	200 épocas sin augmentation extra	0.9565	0.9950	0.9986	1.0000	−0.44 pp	−0.44 pp	Revertido

Resultado en test: mAP50-95 = 0.9522, mAP50 = 0.9950, Precision = 0.9920, Recall = 1.0000.

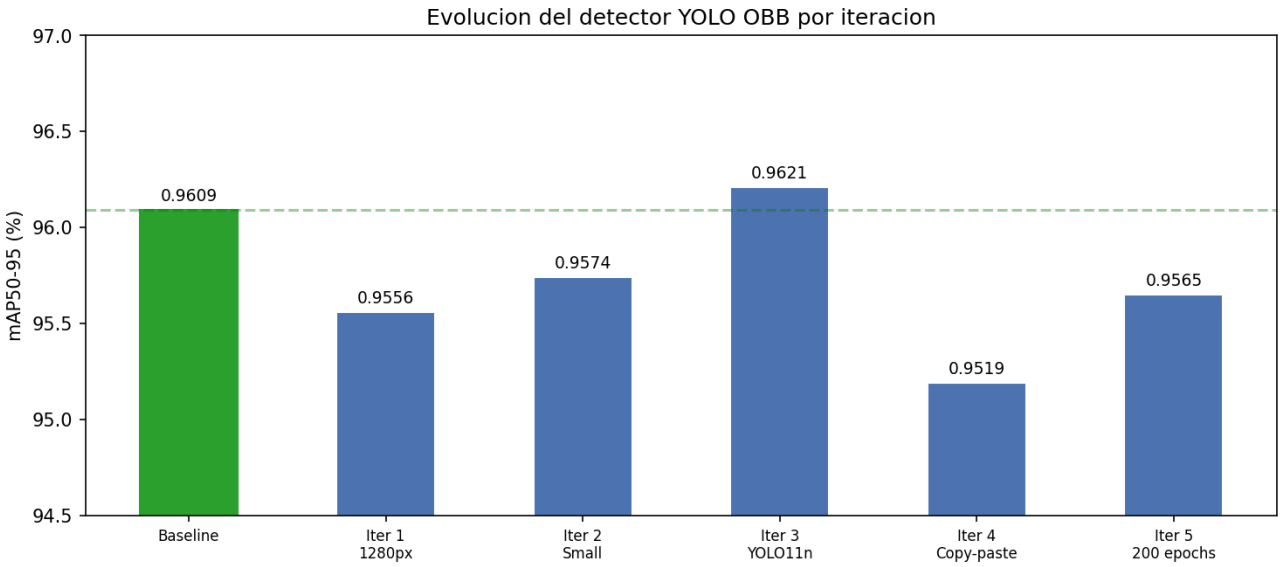

Figura A.1. *Evolución del mAP50-95 del detector por iteración.*

Detalle por iteración:

1. **Baseline (yolov8n-obb, 640 px, 100 épocas).** Configuración inicial con la variante nano de YOLOv8 OBB, resolución de 640 píxeles, lotes de 16 imágenes y paciencia de 50 épocas para early stopping. Alcanzó un mAP50-95 de 0.9609 con Recall perfecto, estableciendo un techo alto desde el primer experimento.
2. **Iter 1: Resolución 1280 px.** Se duplicó la resolución de entrada para evaluar si mayor detalle espacial mejoraba la localización fina. El mAP50-95 bajó a 0.9556 (−0.53 pp); el aumento de resolución no aportó información adicional útil para una tarea de una sola clase con objetos de tamaño relativamente grande en la imagen.
3. **Iter 2: Cambio de tamaño del modelo (yolov8s-obb).** Se escaló la arquitectura de nano a small para incrementar la capacidad del modelo. El mAP50-95 fue de 0.9574 (−0.35 pp respecto al baseline), lo que confirmó que la capacidad adicional no se traducía en mejor desempeño para este problema.
4. **Iter 3: Cambio de arquitectura del modelo (yolo11n-obb).** Se probó la generación más reciente de YOLO (v11) en variante nano. Obtuvo 0.9621 (+0.12 pp), la variación más alta observada, pero dentro del margen de ruido del muestreo (< 0.5 pp con 120 imágenes de validación). Se revirtió al baseline por no representar una mejora significativa y para mantener la configuración más simple.
5. **Iter 4: Aumento de data augmentation, 200 épocas.** Se extendió el entrenamiento a 200 épocas y se activó augmentación copy-paste para generar variaciones sintéticas. El mAP50-95 bajó a 0.9519 (−0.90 pp), la mayor caída observada. Los cambios para incorporar data-augmentation adicional introdujo ruido en lugar de mejorar la generalización.
6. **Iter 5: 200 épocas sin augmentación extra.** Se mantuvo el entrenamiento extendido (200 épocas) pero sin copy-paste, para aislar el efecto de las épocas adicionales. El mAP50-95 fue de 0.9565 (−0.44 pp), confirmando que más épocas de entrenamiento no mejoraban un modelo que ya había convergido.

Interpretación: Ninguna iteración superó al baseline de forma significativa (diferencias < 0.5 pp en mAP50-95, dentro del margen de ruido del muestreo con 120 imágenes). La configuración más ligera fue suficiente para una tarea de una sola clase con anotaciones consistentes.

A.2 Evolución del OCR (PP-OCRv4)

El OCR fue el componente con mayor variabilidad entre iteraciones. La Tabla A.2 resume la evolución completa. Las métricas utilizadas son:

- **EM (Exact Match Accuracy):** porcentaje de imágenes donde la lectura predicha coincide exactamente con la referencia, carácter por carácter. Métrica principal del OCR.
- **CER (Character Error Rate):** tasa de error a nivel de carácter, calculada como la distancia de edición (número mínimo de inserciones, eliminaciones o sustituciones de caracteres necesarias para transformar una cadena en otra) entre predicción y referencia, dividida por la longitud de la referencia. Complementa al EM capturando errores parciales.
- **delta vs baseline:** diferencia en puntos porcentuales respecto al baseline.
- **delta vs mejor:** diferencia en puntos porcentuales respecto a la última iteración adoptada.

Tabla A.2. *Comparación de iteraciones del OCR sobre el conjunto de validación (120 imágenes).*

Iteración	Cambio principal	EM	CER	delta vs baseline	delta vs mejor	Decisión
Baseline	Det+rec, sin fine-tuning	4.17%	0.8280	-	-	-
Iter 1	Bypass del detector de texto	15.83%	0.5009	+11.66 pp	+11.66 pp	Adoptado
Iter 2	Variante server	13.33%	0.5327	+9.16 pp	−2.50 pp	Revertido
Iter 3	PP-OCRv4 english-only	30.00%	0.3907	+25.83 pp	+14.17 pp	Adoptado
Iter 4	Fine-tuning con diccionario de dígitos	90.00% (val) / 87.50% (test)	0.0243	+85.83 pp	+60.00 pp	Adoptado
Iter 5	Padding de 5 px en el recorte	85.00%	0.0523	+80.83 pp	−5.00 pp	Revertido
Iter 6	Máscara LAB v5 + fine-tuning	89.17% (val) / 92.50% (test)	0.0262	+85.00 pp (val)	−0.83 pp (val) / +5.00 pp (test)	**Adoptado**

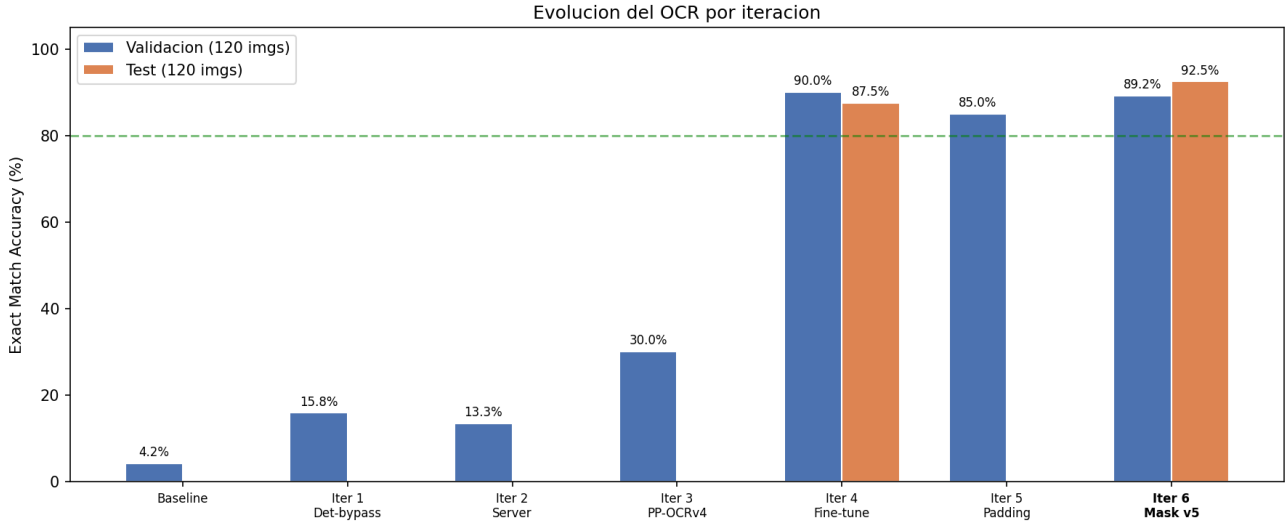

Figura A.2. *Evolución del Exact Match del OCR por iteración.*

Detalle por iteración:

1. **Baseline (det+rec, PP-OCRv5 mobile).** Configuración de fábrica de PaddleOCR: el detector de texto localiza regiones y el reconocedor las lee. El 59% de las imágenes no produjo predicción alguna porque el detector, entrenado en texto general, no reconoce la tipografía mecánica de los odómetros.
2. **Iter 1: Bypass del detector de texto.** Se omitió el detector y se pasó el recorte completo directamente al reconocedor. Dado que el recorte YOLO OBB ya delimita el área de dígitos, el detector era redundante. El EM se cuadruplicó (de 4.17% a 15.83%) y las imágenes sin predicción bajaron de 59% a 2%. El nuevo error dominante fue la lectura de dígitos espurios del fondo del recorte (90% de los errores).
3. **Iter 2: Variante server.** Se reemplazó el modelo mobile por el server (mayor capacidad). El vocabulario multilingüe (chino/japonés/inglés) introdujo confusión adicional en dígitos mecánicos, empeorando el EM en 2.5 pp. Se revirtió a mobile.
4. **Iter 3: PP-OCRv4 english-only.** Se cambió de PP-OCRv5 a PP-OCRv4 con vocabulario exclusivamente latino. El vocabulario reducido disminuyó la confusión y el EM casi se duplicó (de 15.83% a 30.00%). Los dígitos espurios bajaron de 90% a 60% de los errores.
5. **Iter 4: Fine-tuning con diccionario de dígitos.** Se ajustó el modelo PP-OCRv4 sobre los recortes de odómetros con un diccionario restringido a los 10 dígitos. El EM saltó de 30% a 90% (+60 pp), el mayor avance del proyecto. Los dígitos espurios desaparecieron por completo y el error residual pasó a ser la omisión de dígitos (58% de los errores).
6. **Iter 5: Padding de 5 px en el recorte.** Se expandió el recorte OBB en 5 px para intentar recuperar dígitos cortados en los bordes. El EM empeoró 5 pp: el contexto adicional de fondo dificultó el reconocimiento, y la omisión de dígitos aumentó en lugar de reducirse (el problema real era el colapso de ceros iniciales, no dígitos cortados). Se revirtió.
7. **Iter 6: Máscara LAB v5 + re-entrenamiento.** Se refinó la máscara decimal para cubrir tonos magenta y púrpura que escapaban al filtro anterior, y se reentrenó el modelo con los recortes regenerados. En validación el EM bajó marginalmente (−0.83 pp, una sola muestra), pero en test mejoró 5 pp (de 87.50% a 92.50%), concentrando la ganancia en medidores con decimales (de 86.90% a 94.05%).

Interpretación: El salto más significativo fue el fine-tuning con diccionario restringido a dígitos (+60 pp). La Iter 6 redujo ligeramente el rendimiento en validación (−0.83 pp) pero mejoró en test (+5 pp), concentrando la ganancia en medidores con decimales (de 0.8690 a 0.9405). El error residual dominante es la omisión de dígitos (66.7% de los errores en test).

A.3 Evaluación end-to-end

La evaluación integrada del pipeline (detector + preprocesamiento + OCR) se ejecutó sobre las 120 imágenes del conjunto de test con un umbral de validación de 0.7. Las métricas utilizadas son:

- **Tasa de coincidencia (*match rate* / *accuracy*):** porcentaje de imágenes donde la lectura normalizada (sin ceros a la izquierda) coincide con la referencia. Métrica principal del pipeline integrado.
- **Coincidencia estricta (*strict match*):** comparación carácter por carácter sin normalización; diferencias de padding cuentan como error.
- **Tasa de lectura (*readable rate*):** porcentaje de imágenes para las cuales el pipeline devuelve alguna lectura.
- **Tasa de validación automática (*auto-validation rate*):** porcentaje de casos clasificados como *valid* (confianza global mayor o igual al umbral de 0.7).
- **Precisión de validación automática (*auto-validation precision*):** porcentaje de casos *valid* que efectivamente son correctos.
- **Tasa de revisión (*review rate*):** porcentaje de casos clasificados como *needs_review*.

- **Tasa de no-detección (*no-detection rate*):** porcentaje de imágenes donde el detector no localizó un odómetro.
- **Latencia media por imagen:** tiempo promedio de procesamiento por imagen, incluyendo todos los componentes del pipeline.

Tabla A.3. *Métricas principales de la evaluación end-to-end.*

Métrica	Valor
Tasa de coincidencia	95.83% (115/120)
Coincidencia estricta	94.17% (113/120)
Tasa de lectura	100.00% (120/120)
Tasa de validación automática	93.33% (112/120)
Precisión de validación automática	96.43% (108/112)
Tasa de revisión	6.67% (8/120)
Tasa de no-detección	0.00% (0/120)
Latencia media por imagen	435 ms

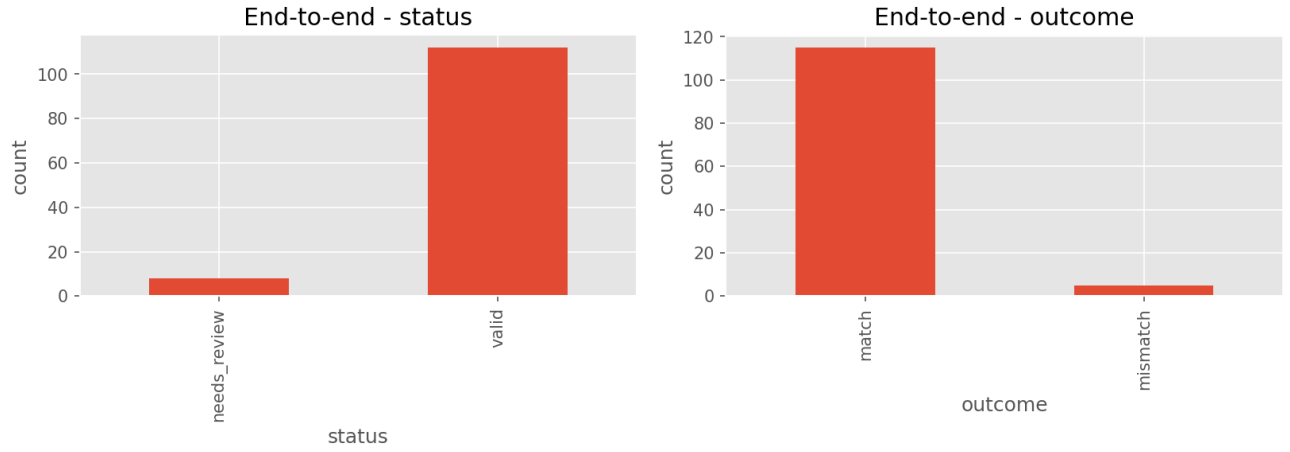

Figura A.3. *Distribución de status y outcome en la evaluación end-to-end.*

Tabla A.4. *Desempeño por subgrupos en la evaluación end-to-end.*

Subgrupo	Total	Tasa de coincidencia
Con decimales	84	97.62%
Sin decimales	36	91.67%
4 dígitos	63	93.65%
5 dígitos	57	98.25%
Fondo blanco	115	95.65%
Fondo negro	5	100.00%

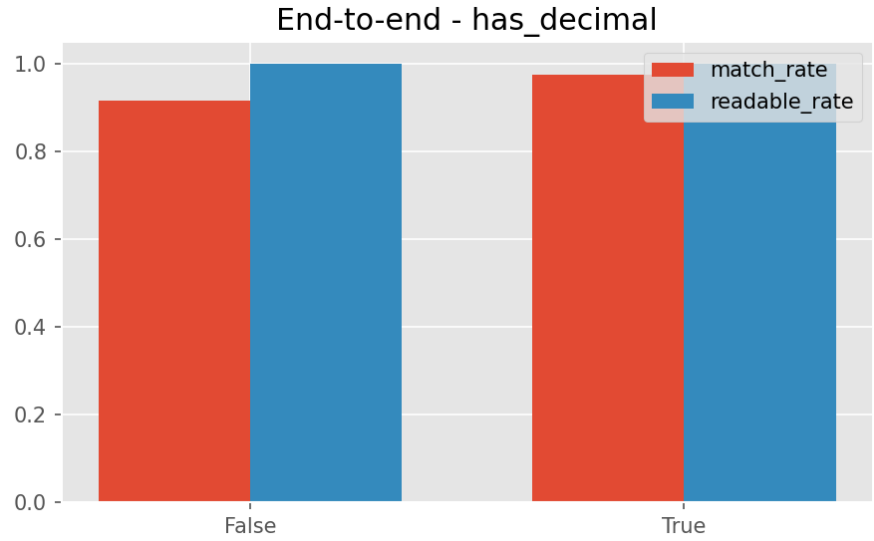

Figura A.4. *Desempeño por subgrupo (con/sin decimales).*

La Figura A.5 complementa el análisis por longitud de lectura: los medidores de 5 dígitos presentan mejor rendimiento (98.25%) que los de 4 dígitos (93.65%).

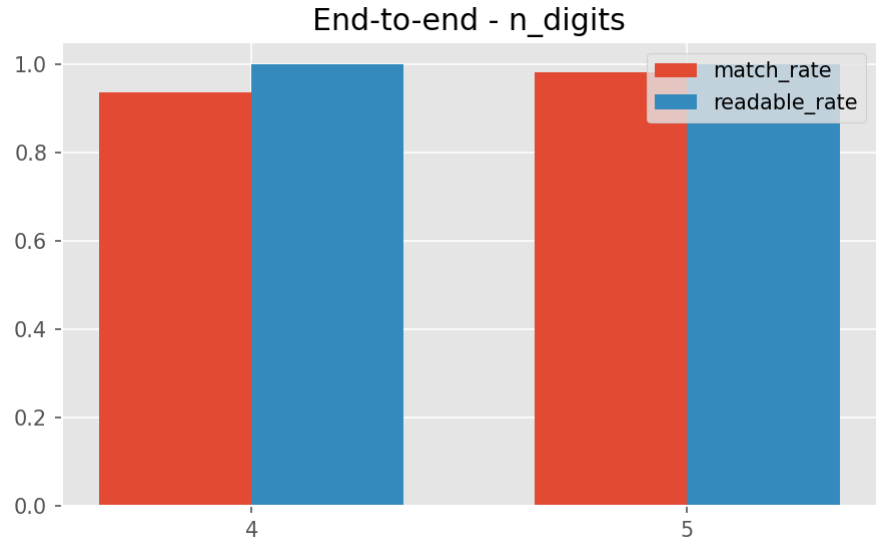

Figura A.5. *Desempeño por subgrupo (longitud de lectura).*

Interpretación: La exactitud end-to-end (95.83%) supera al Exact Match del OCR aislado (92.50%) porque la comparación normalizada ignora diferencias de padding en ceros a la izquierda. La brecha entre medidores con decimales (97.62%) y sin decimales (91.67%) es consistente con el sesgo de posición documentado en el análisis de explicabilidad (sección 5.2 del informe principal). El pipeline logró leer el 100% de las imágenes del split de test sin fallos de detección.

A.4 Validación piloto

La validación piloto evaluó el pipeline sobre 300 imágenes capturadas por operarios en campo, comparando la lectura del sistema con el valor digitado manualmente. Las métricas son las mismas de la evaluación end-to-end (sección A.3), con la diferencia de que la referencia es la lectura digitada por el operario y no una transcripción verificada manualmente.

Tabla A.5. *Métricas principales de la validación piloto.*

Métrica	Valor
Tasa de coincidencia	82.67% (248/300)
Tasa de lectura	92.67% (278/300)
Tasa de validación automática	83.33% (250/300)
Precisión de validación automática	90.40% (226/250)
Tasa de no-detección	6.67% (20/300)
Latencia media por imagen	1153 ms

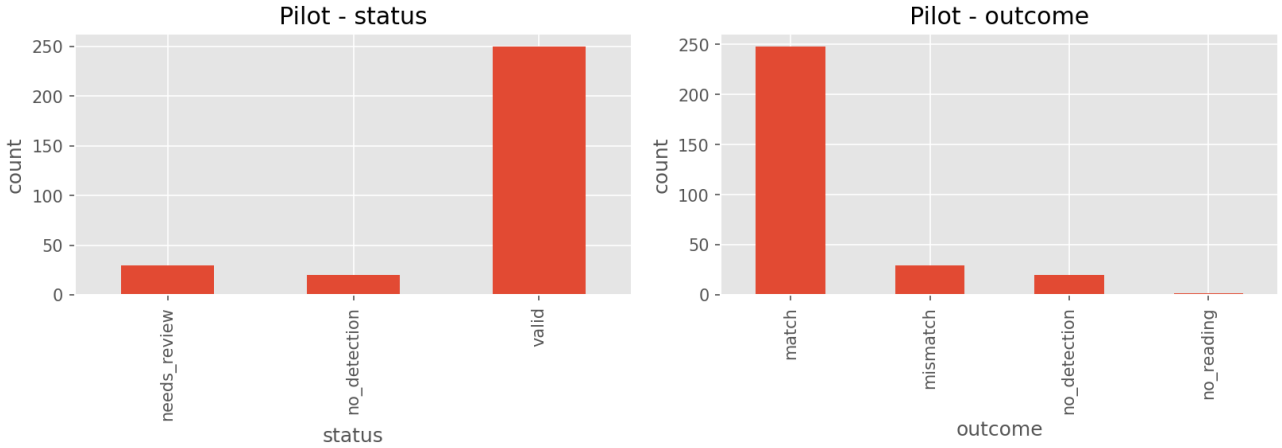

Figura A.6. *Distribución de status y outcome en la validación piloto.*

Tabla A.6. *Clasificación de los 20 casos sin detección en el piloto.*

Categoría	Cantidad	Descripción
Imagen sin medidor	12	Fachadas, portones, tuberías, tapas cerradas
Display no legible	2	Obstrucción o empañamiento extremo que impide leer los dígitos
Fallo del detector por condiciones adversas	4	Suciedad, inclinación u odómetro poco claro
Fallo del detector por modelo subrepresentado	2	Tipografía o diseño subrepresentado en entrenamiento

De las 300 imágenes, 14 no contienen un medidor con odómetro legible. Las 12 imágenes sin medidor corresponden a fotografías de fachadas, portones, tuberías expuestas y tapas cerradas. Los 2 casos con display no legible corresponden a medidores cuyo odómetro resulta imposible de leer: uno presenta el plástico protector muy borroso y obstruido, y otro tiene el display empañado con gotas de agua que impiden distinguir los dígitos. En estos 14 casos el sistema no emitió lectura ni generó falsos positivos. Sobre las 286 imágenes que contienen un medidor procesable, la tasa de coincidencia es de **86.71%** (248/286).

La Figura A.7 muestra ejemplos representativos de las imágenes sin medidor y los casos con display no legible.

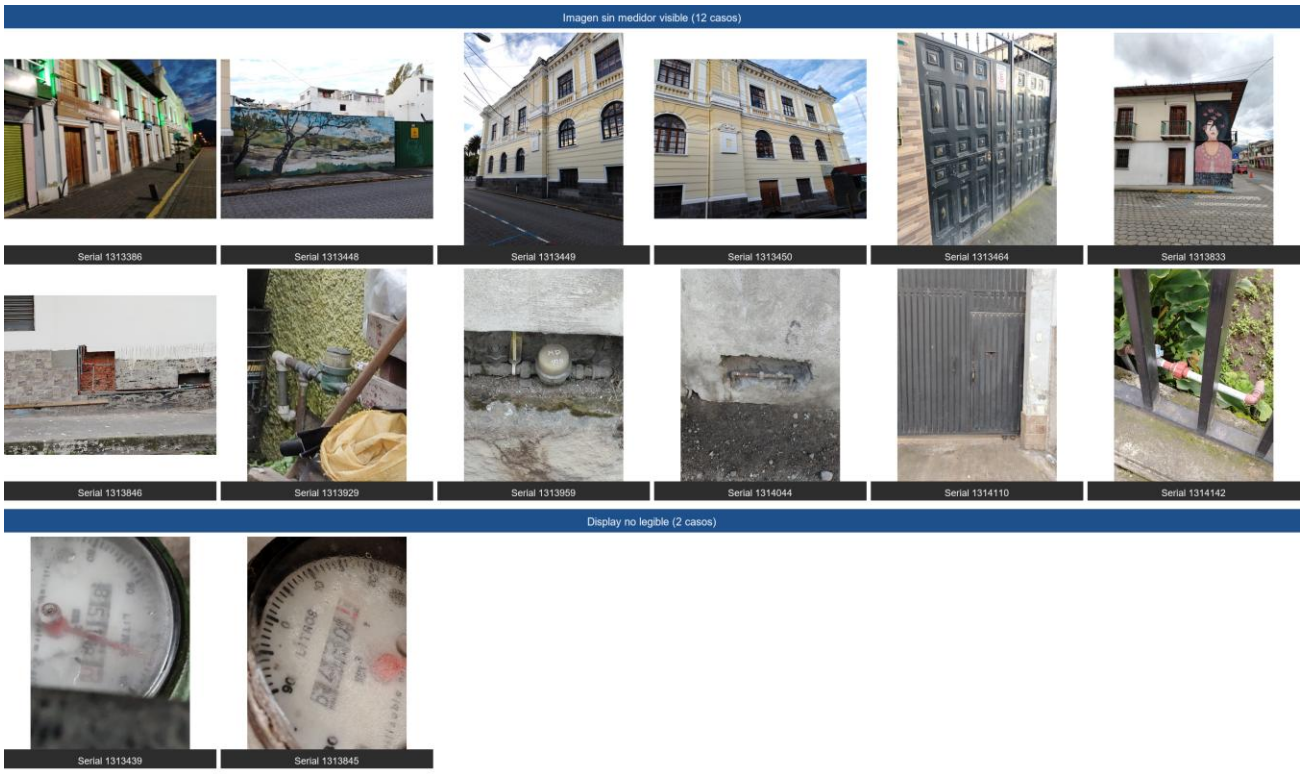

Figura A.7. *Imágenes sin medidor visible y casos con display no legible.*

Los 6 fallos reales del detector se dividen en dos subcategorías. Cuatro casos corresponden a condiciones adversas de imagen: suciedad acumulada con lectura posible pero desafiante, captura desde ángulo cerrado, odómetro poco claro y medidor inclinado respecto a la cámara (en este último caso la lectura era clara para un revisor humano). Los 2 casos restantes corresponden a modelos de medidor cuya tipografía o diseño está subrepresentado en el conjunto de entrenamiento: un medidor antiguo marca KENT con tipografía no estándar y un modelo cuyo diseño visual difiere significativamente de los medidores del dataset. La Figura A.8 presenta estos 6 casos.

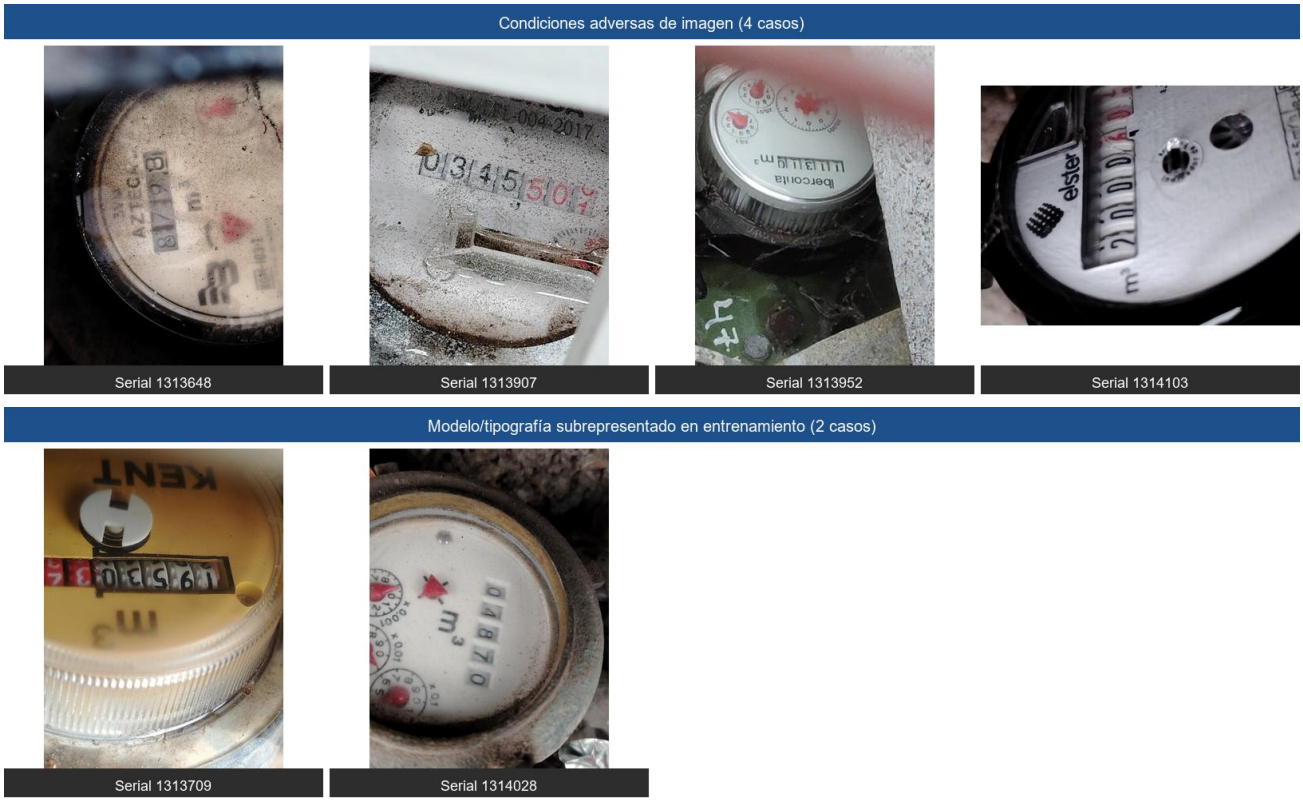

Figura A.8. *Fallos reales del detector, agrupados por causa.*

Tabla A.7. *Clasificación de los 32 errores de lectura en el piloto.*

Causa raíz	Cantidad	Ejemplos representativos
Omisión de dígitos (sesgo de posición)	14	Esperado: "3900", Predicho: "390"; Esperado: "1107", Predicho: "107"
Calidad visual degradada	7	Medidores sucios, empañados u obstruidos
Orientación ambigua	4	Esperado: "10006", Predicho: "9000" (invertido 180°)
Imagen rotada o inclinada	3	Fotos tomadas en posición incómoda con distorsión
Error del operario	2	Imagen sin medidor o lectura digitada inconsistente
Otros (dígitos espurios, off-by-one)	2	Vegetación ocluyendo display en muestra 1313961

Interpretación: La omisión de dígitos sigue siendo el error dominante (14 de 32), consistente con el hallazgo del análisis de explicabilidad. La brecha entre el entorno controlado (95.83%) y el operativo (82.67%) se explica por condiciones propias del campo: medidores sucios, imágenes inclinadas e imágenes que no contienen un medidor.

Anexo B - Análisis de robustez

B.1 Sensibilidad al umbral de validación

Se ejecutó una barrida de umbrales (*threshold sweep*) sobre los resultados de ambas evaluaciones, recalculando las métricas operativas sin re-ejecutar el pipeline. Esto permite evaluar cómo cambia el comportamiento del sistema al modificar el nivel de confianza exigido para la validación automática.

Tabla B.1. *Tradeoff del umbral de validación en end-to-end (test) y piloto.*

Umbral	Val. automática (test)	Precisión (test)	Errores (test)	Val. automática (piloto)	Precisión (piloto)	Errores (piloto)
0.60	100.00%	95.83%	5	89.67%	89.96%	27
0.65	100.00%	95.83%	5	88.00%	90.15%	26
0.70	**93.33%**	**96.43%**	**4**	**83.33%**	**90.40%**	**24**
0.75	85.00%	98.04%	2	70.33%	91.47%	18
0.80	60.00%	100.00%	0	53.33%	90.62%	15

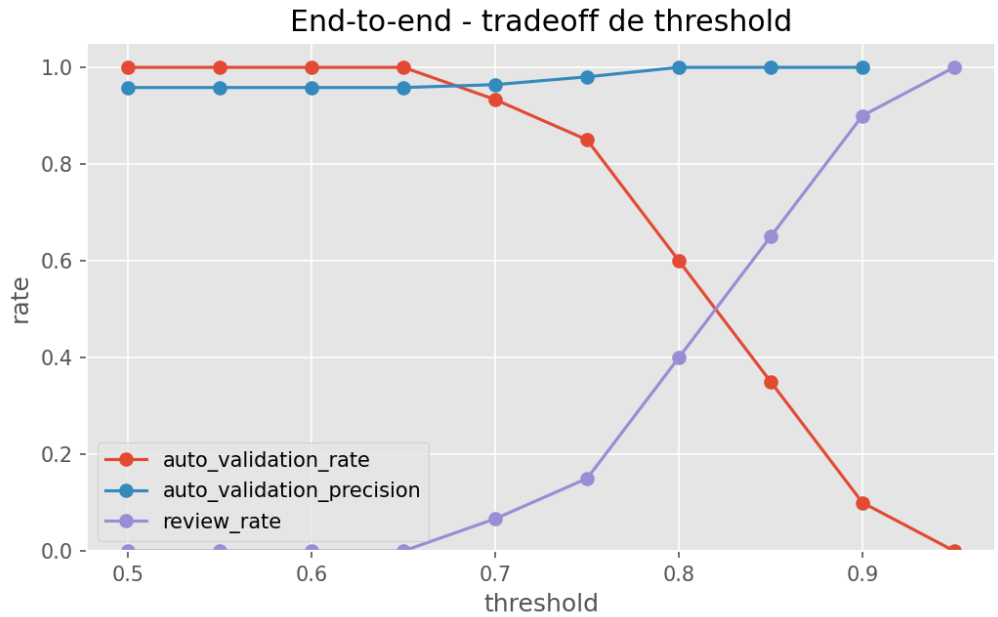

Figura B.1. *Curvas de tradeoff del umbral de validación en pruebas end-to-end.*

En el piloto (Figura B.2) se observa un comportamiento distinto: la curva de precisión se mantiene prácticamente plana entre umbrales de 0.50 y 0.85, lo que indica que los errores no se concentran en las confianzas bajas.

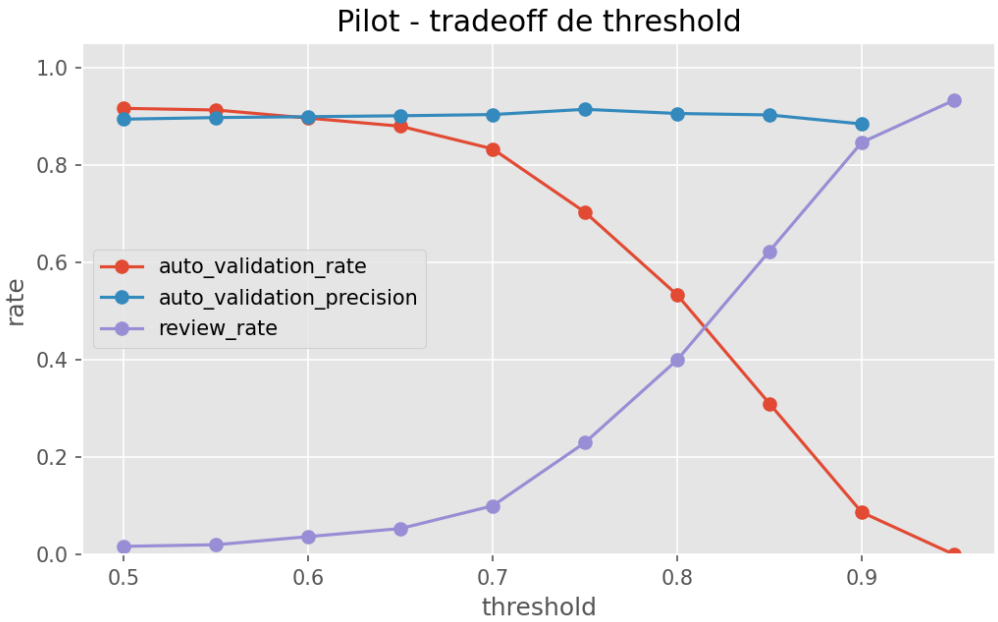

Figura B.2. *Curvas de tradeoff del umbral de validación en el piloto.*

Interpretación: En el test controlado, subir el umbral a 0.80 elimina los 4 errores auto-validados (los 4 tenían confianza entre 0.70 y 0.79), pero envía el 40% de los casos a revisión. En el piloto, la precisión se mantiene plana (~90%) entre umbrales de 0.50 y 0.85: subir el umbral no mejora la calidad de las decisiones automáticas, solo reduce la cobertura. Esto indica que en datos operativos la confianza global del modelo no es un buen discriminador de errores. El umbral de 0.7 ofrece un equilibrio razonable para un despliegue con revisión humana.

B.2 Sensibilidad al preprocesamiento: efecto de la máscara decimal

La máscara decimal LAB pasó por varias versiones. La Tabla B.2 compara el impacto de la última versión adoptada (v5) frente a la inmediatamente anterior (v4) sobre el mismo modelo fine-tuned.

Tabla B.2. *Comparación de máscara v4 vs v5 sobre el conjunto de test.*

Métrica	Máscara v4 (Iter 4)	Máscara v5 (Iter 6)	Delta
EM global	87.50%	92.50%	+5.00 pp
EM con decimales	86.90%	94.05%	+7.15 pp
EM sin decimales	88.89%	88.89%	0.00 pp
Errores atribuibles a masking	-	0 de 5	-

Interpretación: La mejora de la última versión de la máscara se concentra enteramente en medidores con decimales (+7.15 pp), sin afectar a los medidores con solo enteros. El diagnóstico confirma que ninguno de los 5 errores restantes en el subgrupo decimal es atribuible a una fuga de la máscara.

B.3 Sensibilidad a la orientación

De los 5 errores en la evaluación end-to-end, 2 involucran orientación ambigua (delta < 0.10 en dual-OCR). En el piloto, 4 de los 32 errores de lectura corresponden a orientación incorrecta, y 2 casos adicionales no produjeron lectura por ambigüedad total (delta = 0.00).

Tabla B.3. *Fallos atribuibles a orientación.*

Evaluación	Casos con orientación ambigua	Impacto
End-to-end (test)	2 de 5 errores	Lecturas invertidas o truncadas
Piloto	6 de 52 fallos totales	4 mismatch + 2 no_reading

Interpretación: El módulo de orientación es un punto de mejora identificado. Los casos con delta bajo indican que el dual-OCR no logra distinguir la orientación correcta. Mejorar este módulo podría reducir tanto los errores de lectura como los casos sin lectura.

B.4 Comportamiento frente a datos fuera de dominio

El piloto incluyó imágenes que no forman parte del dominio de entrenamiento del sistema: fotografías sin medidor, medidores con display ilegible, modelos subrepresentados en el entrenamiento y medidores con fotos tomadas en posiciones incómodas. La Tabla B.4 resume el comportamiento del sistema ante estos escenarios.

Tabla B.4. *Respuesta del sistema a datos fuera de dominio en el piloto.*

Escenario	Cantidad	Respuesta del sistema
Imagen sin medidor visible	12	Sin detección, no emitió lectura
Display no legible (obstrucción/empañamiento extremo)	2	Sin detección, no emitió lectura
Modelo/tipografía subrepresentados en entrenamiento	2	Sin detección, no emitió lectura
Imagen muy rotada/inclinada	3	Lectura incorrecta o parcial
Error del operario (lectura digitada)	2	Lectura del sistema difiere de la digitada

Interpretación: En las 14 imágenes sin medidor o con display no legible, el sistema no emitió lectura ni generó falsos positivos. Los 2 casos de modelos subrepresentados evidencian una limitación del detector ante tipografías y diseños no incluidos en el entrenamiento. Las imágenes rotadas y los errores del operario representan condiciones de campo que el sistema no puede resolver sin intervención.

Anexo C - Interpretación técnica de los resultados

C.1 Confiabilidad y consistencia del modelo

Los tres niveles de evaluación muestran resultados coherentes entre sí:

- El detector es estable: la configuración baseline resultó ser la mejor y ninguna de las cinco variaciones la superó.
- El OCR mejoró progresivamente mediante decisiones de ingeniería específicas al dominio (bypass del detector, fine-tuning con diccionario restringido, máscara decimal).
- La evaluación end-to-end confirmó que ambos componentes funcionan de forma integrada: 95.83% de exactitud del pipeline frente a 92.50% del OCR aislado.
- La validación piloto reveló una brecha respecto al entorno controlado (82.67% vs 95.83%), explicada por condiciones de campo no presentes en el test set.

C.2 Respaldo de las decisiones metodológicas

Decisión	Evidencia que la respalda
Usar YOLO baseline en lugar de modelos más grandes	Tabla A.1: ninguna iteración mejoró significativamente
Bypass del detector de texto de PaddleOCR	Tabla A.2: +11.7 pp al eliminarlo (Iter 1)
Fine-tuning con diccionario restringido	Tabla A.2: +60 pp (Iter 4), el mayor salto del proyecto
Máscara decimal LAB v5	Tabla B.2: +7.15 pp en subgrupo con decimales, 0 errores por masking
Umbral de validación 0.7	Tabla B.1: equilibrio razonable entre autonomía y precisión
Esquema *human-in-the-loop*	Tablas A.5 y B.1: la precisión en piloto (~90%) justifica revisión humana

C.3 Hallazgos principales

El análisis de explicabilidad (Grad-CAM + oclusión por bandas verticales) reveló que el modelo OCR internalizó un patrón de omisión de las posiciones finales del odómetro. Este sesgo fue inducido por la composición del dataset de entrenamiento: el 70% de las muestras corresponde a medidores con decimales, donde la máscara LAB deja las últimas posiciones vacías. El modelo generalizó este patrón al subgrupo de medidores con solo dígitos enteros, produciendo errores por omisión de dígitos.

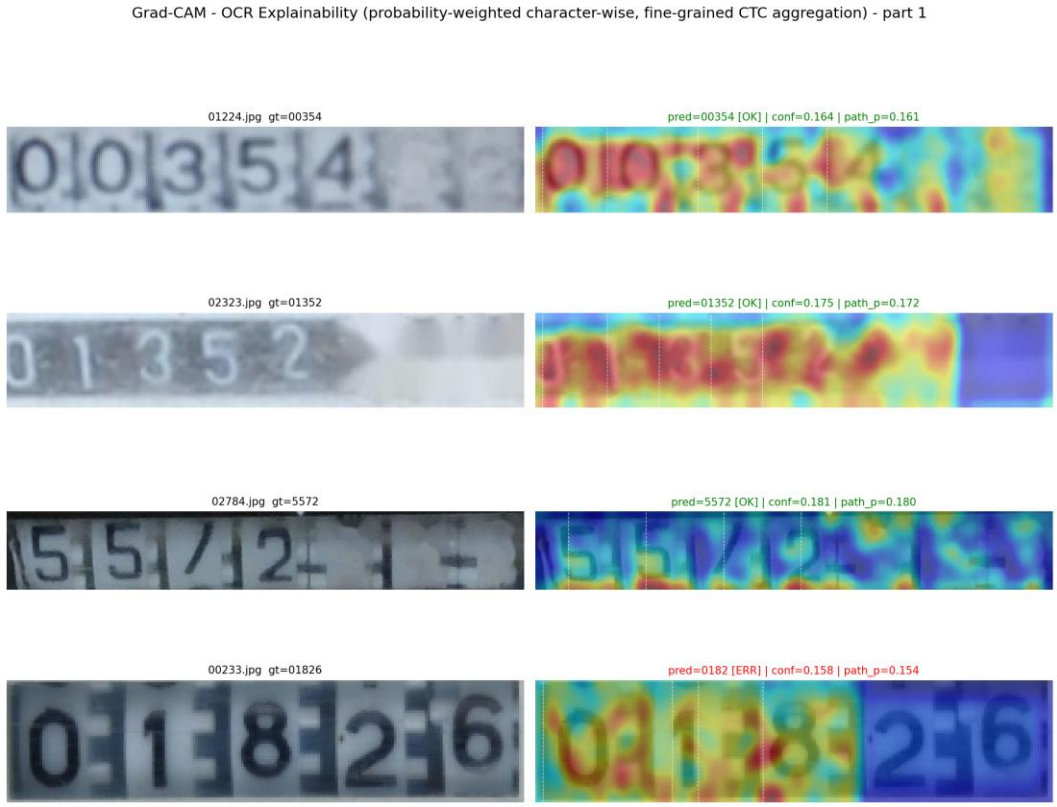

Figura C.1. *Mapas Grad-CAM del OCR mostrando el enfriamiento en posiciones finales.*

La Figura C.2 muestra un caso concreto: en la muestra 00233 (referencia "01826", predicción "0182"), el Grad-CAM se concentra en las primeras cuatro posiciones y se enfría en la quinta, mientras que la oclusión confirma que cubrir esa posición no altera la predicción (correlación 0.10).

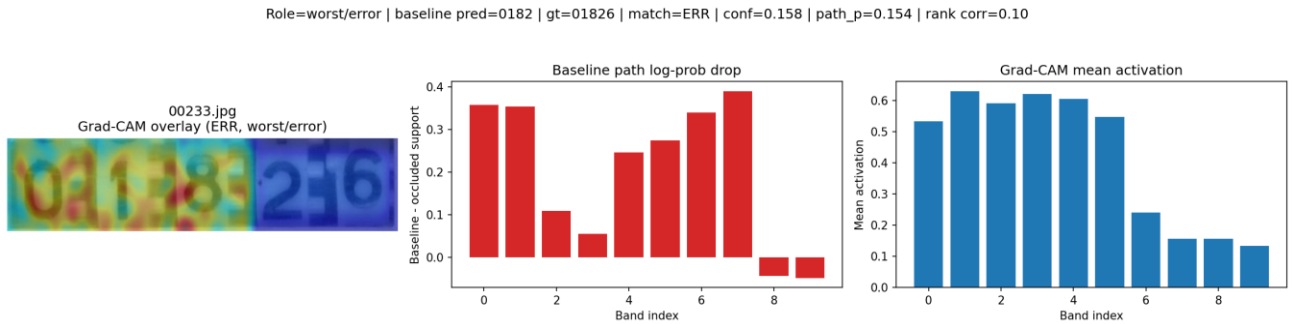

Figura C.2. *Comparación Grad-CAM vs. oclusión en caso de error (predicción "0182" vs. referencia "01826").*

Este hallazgo tiene dos implicaciones directas:

1. **Explica el error dominante:** la omisión de dígitos representa el 66.7% de los errores en test y 14 de 32 en el piloto.
2. **Permite identificar mejora prioritaria:** aumentar la proporción de muestras de medidores con solo dígitos enteros en el dataset de entrenamiento.

C.4 Relación con los objetivos del proyecto

Objetivo	Resultado	Evidencia
Desarrollar un prototipo funcional de lectura de medidores	Cumplido	Pipeline integrado con API y demo funcional
Alcanzar al menos 80% de coincidencia en lecturas operativas	Cumplido	82.67% en piloto (Tabla A.5); 86.71% sobre imágenes con medidor procesable
Identificar limitaciones y rutas de mejora	Cumplido	Sesgo de posición, orientación ambigua, calidad visual (Tablas A.7, B.3)
Incorporar análisis de explicabilidad	Cumplido	Grad-CAM + oclusión sobre OCR, Eigen-CAM sobre detector (sección 5.2 del informe)